BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH



HUỲNH LÊ THANH HẢI

DỰ ĐOÁN VÀ TRỰC QUAN HÓA BỆNH SỐT XUẤT HUYẾT Ở BRAZIL QUA MÔ HÌNH SPATIO-TEMPORAL GRAPH ATTENTION NETWORKS

BÁO CÁO ĐỒ ÁN

NGÀNH KHOA HỌC MÁY TÍNH

TP. HỒ CHÍ MINH, 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH



HUỲNH LÊ THANH HẢI

DỰ ĐOÁN VÀ TRỰC QUAN HÓA BỆNH SỐT XUẤT HUYẾT Ở BRAZIL QUA MÔ HÌNH SPATIO-TEMPORAL GRAPH ATTENTION NETWORKS

Mã số sinh viên: 2251012054

BÁO CÁO ĐỒ ÁN

NGÀNH KHOA HỌC MÁY TÍNH

Giảng viên hướng dẫn: TIẾN SĨ. LÊ QUANG MINH

TP. HỒ CHÍ MINH, 2025

TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập – Tự do – Hạnh phúc

GIẤY XÁC NHẬN

Tôi tên là: HUỲNH LÊ THANH HẢI

Ngày sinh: 09/08/2004 Nơi sinh: TP. HỒ CHÍ MINH

Chuyên ngành: KHOA HỌC MÁY TÍNH Mã sinh viên: 2251012054

Tôi đồng ý cung cấp toàn văn thông tin đồ án ngành hợp lệ về bản quyền cho Thư viện Trường Đại học Mở Thành phố Hồ Chí Minh. Thư viện Trường Đại học Mở Thành phố Hồ Chí Minh sẽ kết nối toàn văn thông tin đồ án vào hệ thống thông tin khoa học của Sở Khoa học và Công nghệ Thành phố Hồ Chí Minh.

Ký tên

(Ghi rõ họ và tên)

Ý KIẾN CHO PHÉP BẢO VỆ ĐỒ ÁN/ BÁO CÁO ĐỒ ÁN NGÀNH

CỦA GIẢNG VIÊN HƯỚNG DẪN

Giảng viên hướng dẫn: TIẾN SĨ. LÊ QUANG MINH

Sinh viên thực hiện: HUỲNH LÊ THANH HẢI Lớp: DH22CS01C

Ngày sinh: 09/08/2004 Nơi sinh: TP. HỒ CHÍ MINH

Tên đề tài: DỰ ĐOÁN VÀ TRỰC QUAN HÓA BỆNH SỐT XUẤT HUYẾT Ở BRAZIL QUA MÔ HÌNH SPATIO-TEMPORAL GRAPH ATTENTION NETWORKS.

Ý kiến của giảng viên hướng dẫn về việc cho phép sinh viên được bảo vệ đồ án/ khóa luận trước Hội đồng: .....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Thành phố Hồ Chí Minh, ngày ... tháng ... năm ……

Người nhận xét

LỜI CẢM ƠN

Lời cảm ơn và sự kính trọng gửi đến quý vị thầy cô cùng Trường Đại Học Mở đã hỗ trợ cho đồ án về quy trình và các nền tảng học thuật.

Cảm ơn Thầy hướng dẫn: TS. Lê Quang Minh đã tạo dựng ý tưởng và nền tảng cho kỹ thuật học máy Graph Attention Networks và các lý luận học máy nâng cao ứng dụng vô bệnh sốt xuất huyết, thực nghiệm trên nền tảng lớn ở Brazil và đem ngược nghiên cứu về cho Việt Nam.

Cảm ơn dự án Mosqlimate [1] đã hỗ trợ cung cấp đầy đủ bộ dữ liệu đa nền tảng phong phú cùng các chuẩn hóa theo dịch tễ học đáp ứng tiêu chuẩn đạo đức y học.

Cảm ơn quý Bác sĩ từ Bệnh viện Nhiệt Đới đã có cuộc phỏng vấn sâu hỗ trợ cung cấp thông tin về bệnh sốt xuất huyết cách áp dụng và phương pháp nghiên cứu và lí luận thực tiễn tại phòng chỉ đạo tuyến làm tiền đề cho đồ án.

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TÓM TẮT ĐỒ ÁN

Đồ án áp dụng các kỹ thuật từ nền tảng Graph Neural Networks (GNNs) để áp dụng vô bệnh sốt xuất huyết. Sử dụng bộ dữ liệu lớn thực tế trải dài từ 2010 đến 2024 tại Brazil cùng nền tảng dữ liệu đa dạng nhằm cải thiện mô hình nghiên cứu vô Graph Attention Networks. Khảo sát sơ bộ từ bộ dữ liệu, cải thiện bằng phỏng vấn sâu chuyên gia, xây dựng đồ thị bằng cách tạo cạnh – edge bằng bản đồ và liên kết hành chính, nút – node là các khu đô thị có cập bậc và sự liên kết. Bổ sung biến đặc trưng và nhãn – feature & label từ các biến khí hậu, môi trường, dữ liệu dân số và dữ liệu tĩnh. Qua đó xây dựng pipeline từng bước đồ thị Graph Attention Networks áp dụng vô bệnh sốt xuất huyết. Huấn luyện và phân tích mô hình thông qua yếu tố không gian và thời gian bằng geocode và epiweek (địa phương và tuần dịch tễ). Rút ra kết quả mô hình và ghi lại mô hình tốt nhất, hạn chế biến ngoại lai (outlier) và cải thiện tách rõ các thông số tương đối và thông số top1% trimmed ngoại lệ 1%. Sử dụng kết quả để tạo bảng điều khiển trực quan hóa. Thông qua đó xây dựng từng bước chuyển hóa làm nền tảng trực quan hóa đa lớp và trực quan hóa chi tiết. Có thể lưu lại và chạy offline, có thể nạp dễ dàng qua các nền tảng khác nhờ parquet. Rút ra kết luận về mô hình Graph Attention Networks có yếu tố không gian và thời gian vào bệnh sốt xuất huyết dẫn đến cách thức và góc độ phát triển trong tương lai.

TÓM TẮT KHÓA LUẬN
(PHIÊN BẢN TIẾNG ANH)

The project based on Graph Neural Networks (GNNs) in order to enhance performance the dengue infection in Barzil to prediction. Using the big dataset from 2010 to 2024 in Brazil and the varied database to enhance the model research in Graph Attention Networks. Preliminary exploration and dataset analysis from the database, enhance by deep interviewing of doctor, building Graph by created edge, which was made by maps and inter-municipal linkages, but also node, which was urban areas with levels and polygons. Adding dataset features and labels from enviromental, weather variations, population data, static data. Based on these factors to build the pipeline Graph Attention Networks applied to dengue fever infection. Training and analyzing using model Spatial Temporal Graph Attention Networks by geocode and epiweek (municipalities and epidemiological weeks). Conclusions and recording checkpoints the best one, solve the case have outlier and improved by carefully separating comparative parameters and top 1% parameters by trimmed the 1% outlier to processing special analyst case. Using results to create a visualization dashboard. By reults after trainning models fully to build steps convert data, to visualize multiple layers exploratory and details. We can save and run it offline, can easily import data to other database by parquet. Overall about the model Graph Attention Network with Spatial - Temporal factors into dengue fever infection, which leads to ways and varied development perspectives in the future.

MỤC LỤC

LỜI CẢM ƠN **3**

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN **4**

TÓM TẮT ĐỒ ÁN **5**

TÓM TẮT KHÓA LUẬN **6**

(PHIÊN BẢN TIẾNG ANH) **6**

DANH MỤC TỪ VIẾT TẮT **11**

DANH MỤC HÌNH VẼ **12**

DANH MỤC BẢNG **13**

MỞ ĐẦU **14**

Chương 1. KHẢO SÁT VÀ TỔNG QUAN 16

1.1. Bối cảnh – Thách thức - Cơ sở lý thuyết - Mục tiêu 16

1.2. Nền tảng dữ liệu 17

1.2.1. Dữ liệu bệnh sốt xuất huyết - Dengue cases 17

1.2.2. Dữ liệu khí hậu – Climate 18

1.2.3. Dữ liệu dân số xã hội - Population 19

1.2.4. Dữ liệu môi trường sinh thái quần xã – Biome 20

1.2.5. Dữ liệu bản đồ và liên kết hành chính 21

1.3. Khảo sát sơ bộ 24

1.4. Góc nhìn bổ sung từ phỏng vấn sâu chuyên gia – Bác sĩ 24

1.5. Thiết kế nút (node) và đặc trưng (feature & label) gốc và bổ sung 26

Chương 2. XÂY DỰNG VÀ HUẤN LUYỆN GRAPH ATTENTION NETWORKS Ở BỆNH SỐT XUẤT HUYẾT 28

2.1. Khởi tạo cạnh & nút – edge &node 28

2.1.1. Mục tiêu 28

2.1.2. Dữ liệu đầu vào & tiền xử lý 28

2.1.3. Phương pháp khởi tạo cạnh – edge 29
2.1.4. Tổng quan: 30
2.1.5. Kết quả: 30
2.2. Hoàn thiện đặc trưng & nhãn – feature & label 30
2.2.1. Mục tiêu 30
2.2.2. Nạp dữ liệu đầu vào 30
2.2.3. Bảo toàn chỉ số nút (node): 31
2.2.4. Ghép dữ liệu: 31
2.2.5. Xử lý điền thiếu và chuẩn hóa: 31
2.2.6. Tạo đặc trưng gốc từ khảo sát và thiết kế: 31
2.2.7. Tạo đặc trưng bổ sung từ khảo sát và thiết kế: 32
2.2.8. Chuẩn hóa & chống trùng lặp 32
2.2.9. Định nghĩa mặt nạ huấn luyện phân tách theo năm: 32
2.2.10. Tạo đặc trưng – feature 32
2.2.11. Tạo nhãn – label 32
2.2.12. Kết quả thực nghiệm 33
2.3. Kiểm tra hiện vật - sanity check 34
2.3.1. Mục tiêu 34
2.3.2. Phương pháp 34
2.3.3. Kết quả 35
2.4. Chuẩn hóa và biến đổi log - scale & log-transform 36
2.4.1. Mục tiêu 36
2.4.2. Phương pháp 36
2.4.3. Kết quả 37
2.5. Kiểm tra sau chuẩn hóa và biến đổi 37
2.5.1. Mục tiêu: 37

2.5.2. Quy trình kiểm tra: 38
2.5.3. Kết quả kiểm định: 38
2.6. Khởi tạo kiến trúc mô hình Temporal GAT multi-head 39
2.6.1. Mô - đun đánh giá — evaluation/metrics.py 39
2.6.2. Kiến trúc mô hình — models/temporal_gat.py 40
2.6.3. Dựng chuỗi & khởi tạo mô hình — trainers/trainer_weekly.py....41
2.6.4. Pipeline huấn luyện-đánh giá - run_global_gat.py....42
2.7. Huyến luyện và đánh giá mô hình Temporal GAT multi-head 43
Chương 3. TRỰC QUAN HÓA DƯỚI DẠNG BẢN ĐỒ THỂ HIỆN SỰ LAN TRUYỀN BỆNH SỐT XUẤT HUYẾT Ở CÁC KHU VỰC CÙNG YẾU TỐ THỜI GIAN 46
3.1. Mục tiêu trực quan hóa 46
3.2. Nền tảng công cụ....46
3.2.1. convert_node_predictions.py — Bước 1 46
3.2.2. Kiểm tra inspect_node_predictions_schema.py — Bước 2 47
3.2.3. Chuẩn bị dự liệu Prepare_visual_data.py – Bước 3 48
3.2.4. Xây dựng tâm đa giác rebuild_centroids.py – Bước 4 50
3.2.5. Kiểm tra và làm sạch cạnh validate_and_fix_edges.py – Bước 5....51
3.3. Bảng điều khiển kết quả dashboard - export_dashboard.py 51
3.3.1. Dòng dữ liệu đầu vào:....52
3.3.2. Kiến trúc hiển thị và tương tác 52
3.3.3. Giao diện người dùng 53
3.3.4. Khía cạnh hiệu năng 54
3.3.5. Tham số chạy và đầu ra 54
3.3.6. Kiểm soát chất lượng hiển thị....54
3.3.7. Hạn chế & hướng mở rộng 54
3.4. Đánh giá và phân tích trực quan & cảm quan....55

TÀI LIỆU THAM KHẢO 59

PHỤ LỤC MINH CHỨNG.....60

DANH MỤC TỪ VIẾT TẮT

STT	Chữ viết đầy đủ	Chữ viết tắt
1	Graph Attention Network	GAT
2	Graph Neural Network	GNN
3	K-Nearest Neighbors	KNN
4	Exponential Linear Unit.	ELU
5	Mean Absolute Error	MAE
6	Root Mean Squared Error	RMSE
7	Symmetric Mean Absolute Percentage Error	SMAPE
8	Coefficient of Determination	R^2

DANH MỤC HÌNH VẼ

Hình 1.1: Bản đồ hành chính Brazil (cấp thành phố) 23
Hình 3.1 Thực Thi buoc1taoedge.py 60
Hình 3.2 Thực Thi buoc2a_taofeature_label.py 60
Hình 3.3 Thực Thi buoc2b_check.py 60
Hình 3.4 Thực thi buoc3_scale_features.py 61
Hình 3.5 Thực thi buoc4_check_scaled.py 61
Hình 3.6: Thực thi huấn luyện và kiểm tra checkpoints gat_global_best.pt 61
Hình 3.7: Thực thi convert_node_predictions.py 61
Hình 3.8: Thực thi inspect_node_predictions_schema.py 62
Hình 3.9: Thực thi prepare_visual_data.py 62
Hình 3.10: Thực thi rebuild_centroids.py 63
Hình 3.11 Thực thi validate_and_fix_edges.py 63
Hình 3.12 Thực thi export_dashboard.py 63

DANH MỤC BẢNG

Bảng 1.1: Dengue_2010.csv 18
Bảng 1.2: Climate_2010.csv 19
Bảng 1.3: IBGE_POPTCU.csv 20
Bảng 1.4: Environ_vars.csv 21
Bảng 1.5: Regic2018.csv 22
Bảng 1.6: Regic2018_clean.csv 22
Bảng 1.7: geojs-100-mun.json 24
Bảng 2.1 Weekly_2010.csv 34
Bảng 2.2: Gat_global_weekly_report.csv 44
Bảng 2.3: Gat_global_summary.json 45
Bảng 3.1: Dashboard_chinhthuc.html 55
Bảng 3.2: Dashboard trình chiếu layer Truth (Thực tế) 56
Bảng 3.3 Dashboard trình chiếu layer Truth (Thực tế) – Prediction (Dự báo) 56
Bảng 3.4 Dashboard trình chiếu địa phương 5208707 57
Bảng 3.5: Dashboard bật đa lớp layer phủ 58

MỞ ĐẦU

Bệnh sốt xuất huyết là một bệnh truyền nhiễm cấp tính do Vector mang mầm bệnh virus Dengue truyền bệnh chính là muỗi vằn Aedes Aegypti ở thế giới nói chung và Brazil lẫn Việt Nam nói riêng. Bệnh gây nhiều biến chứng nguy hiểm như xuất huyết dưới da do rối loạn đông máu dẫn đến rất nhiều biến chứng, thông thường chia ra 4 cấp độ theo bộ y tế nhưng tất cả đều có thể dẫn đến nguy kịch vì sốc do máu rối loạn dẫn đến tử vong. Thông qua đó ở đồ án ngành mong muốn mang lại lợi ích từ việc dự đoán bệnh sốt xuất huyết bùng phát và lây truyền bằng các mô hình học máy tiên tiến như Gat attention networks và các biến thể đồ thị GNNs, qua đó có thể dự đoán sớm hơn tình trạng bùng phát bởi các yếu tố gây nên bệnh chỉ chủ yêu lan truyền qua Vector và có thể xử lý Vector sớm.

Vì Vector là nguyên nhân chính nên thông qua đó sẽ quan sát những yếu tố ảnh hưởng đến sự phát triển và sinh sản Vector nhưng không thể đếm số vector làm lượng nghiên cứu định lượng theo phương pháp phỏng vấn sâu từ chuyên gia – bác sĩ từ bệnh viện Nhiệt Đới bao gồm các đặc trưng:

Số ca sốt xuất huyết theo địa điểm cột mốc thời gian làm cốt lõi, dữ liệu khí hậu làm nền tảng, dữ liệu xã hội bổ trợ, quần xã môi trường sinh thái làm xu hướng và bản đồ cùng liên kết hành chính thể hiện sự vùng tương quan lây lan và trực quan đậm nét nhạt nét.

Bộ dữ liệu được cung cấp bởi dự án mở Mosqlimate [1] của Brazil nhằm giải quyết nhu cầu các bệnh do virus lây truyền từ động vật chân đốt sang người như bệnh sốt xuất huyết bởi vector muỗi vằn Aedes Aegypti. Vì Brazil là một quốc gia thường xuyên gặp vấn đề về bùng phát dịch bệnh nên mong muốn cung cấp cho tất cả các nhà nghiên cứu trong và ngoài nước bộ dataset đã được kiểm định và phát hành bởi các cơ quan chính phủ Brazil là Bộ Y tế Brazil, Viện Địa lý và Thống kê Brazil (IBGE) và các tổ chức Quỹ đổ vốn, mục tiêu tích hợp kết quả dự đoán sớm để ngăn ngừa bùng phát và phân cụm dịch bệnh đã ảnh hưởng nặng nề vì dịch bệnh trong quá khứ. Vì đây là một môi trường nghiên cứu cùng bộ dataset đã được chính phủ thiết lập để bất cứ ai đều có thể đưa ra phương pháp và mô hình đa dạng có thể giải quyết tình trạng bệnh sốt xuất huyết, điều mà chưa được giải quyết triệt để.

Vì vậy với đồ án ngành này mong muốn có thể thử nghiệm mô hình học máy mạng nơ ron thần kinh thực nghiệm vào một quốc gia như Brazil cùng bộ dữ liệu thực tế kéo dài từ năm 2010 đến năm 2024 đã được kiểm định công khai và chuẩn hóa theo dịch tễ học để có thể dự đoán bệnh sốt xuất huyết và chứng minh được Temporal GAT mở đường cho các biến thể GNNs có thể áp dụng vô bệnh sốt xuất huyết một cách tương thích hơn các mô hình học máy khác.

Thông qua thử nghiệm này để có thể đánh giá một cách thực nghiệm về xử lý lượng dữ liệu lớn chạy dài từ 2010 đến 2024, xử lý và áp dụng GNNs cụ thể là GATs theo từng bước và phân tích các tình huống trong quá trình xây dựng GATs vào bệnh sốt xuất huyết và các lỗi thông thường có thể xảy ra và cách xử lý khắc phục cũng như các kỹ thuật trong quá trình xây dựng mạng nơ ron thần kinh tập trung. Các kết quả từ việc thử nghiệm ở quốc gia như Brazil có thể áp dụng ngược lại cho Việt Nam vì tính liên kết dịch tễ học và bệnh sốt xuất huyết khi so sánh ở khu vực nhiệt đới nói chung.

Chương 1. **KHẢO SÁT VÀ TỔNG QUAN**

1.1. Bối cảnh – Thách thức - Cơ sở lý thuyết - Mục tiêu

Brazil là tâm điểm đã trải qua 40 năm liên tiếp ghi nhận những tình huống bùng phát khẩn cấp bệnh sốt xuất huyết do muỗi vằn Aedes gây hậu quả nặng nề cho cộng đồng dân cư và kinh tế [1]. Chỉ với năm 2023, Bộ Y Tế Brazil đã thống kê cả nước ghi nhận 1094 ca tử vong do bệnh sốt xuất huyết [2]. Qua tiếp năm 2024 chỉ trong 11 tuần đầu tiên dịch tễ ghi nhận 650 ca tử vong [2] gây nặng nề gánh nặng xã hội, ngoài ra các nghiên cứu cũng chỉ ra sự thay đổi trong phân bố dịch tễ theo mật độ dân cư, dân số xã hội – nhân khẩu học phản ánh rõ mối liên hệ giữa bệnh truyền nhiễm liên hệ với điều kiện xã hội kinh tế và khả năng tiếp cận dịch vụ y tế.

Trong bối cảnh đó, dự án Mosqlimate được phát triển nhằm kết hợp dữ liệu dịch tễ, khí hậu, dân số xã hội, liên kết hành chính và bản đồ cùng các biến môi trường sinh thái nhằm tiến hành công cụ dự báo sự lan truyền dịch bệnh sốt xuất huyết qua xu hướng thiết kế các mô hình theo không gian - thời gian. Qua đó có thể cảnh báo sớm người dân và tiến hành các giải pháp y tế cùng xử lý dọn dẹp vector gây bệnh.

Thách thức lớn là hệ thống giám sát dịch tễ hiện hiện tại Brazil [1], còn đối mặt với nhiều hạn chế như tình trạng khoanh vùng quá lớn trong chẩn đoán, không kết hợp hoặc báo cáo thiếu dẫn đến sai lệch không gian tâm dịch, bản đồ phân chia vùng quá bao gồm và không sâu chia nhỏ chi tiết, cũng như chỉ có thể thống kế quá trình xảy ra và không nêu lên rõ xu hướng cũng như dự đoán và trực quan xu hướng hướng đi ở giao diện cho người dùng thông thường và cán bộ y tế.

Thông qua đó tạo một khoảng trống cho tri thức phát triển và tăng nhu cầu mô hình thiết thực, cộng đồng y tế cần một công cụ có khả năng hợp nhất đa dữ liệu nhằm hỗ trợ phân bố nguồn lục, khoan vùng và tiến hành xử lý ổ dịch theo không gian – thời gian (tuần - địa phương), hỗ trợ ra quyết định trên nền tảng toán học như lý thuyết đồ thị, lý thuyết mạng neural đồ thị, lý thuyết mạng lưới, lý thuyết phổ đồ thị, lý thuyết dịch tễ học, lý thuyết xác suất, lý thuyết thông tin, đại số tuyến tính và quan trọng nhất là cơ chế tập trung cùng xu hướng ứng dụng hiện đại trí tuệ nhân tạo trong học sâu và khai thác chuỗi dữ liệu thời gian và quan hệ không gian để đưa ra dự báo sâu và phân cụm rõ ràng địa phương.

Mục tiêu tổng quát là xây dựng pipeline và kiểm chứng mô hình Graph Attention Network (GAT) đa-head có thành phần thời gian (Temporal-GAT) và không gian (spatial). Trong nghiên cứu này, mã địa lý – geocode đại diện cho không gian và epiweek đại diện cho thời gian xây dựng đồ thị Spatio-temporal Graph Attention Networks dự báo ca sốt xuất huyết dựa trên tập dữ liệu tại Brazil giai đoạn 2010 – 2024 hoàn thiện hỗ trợ giám sát dịch tễ và ra dấu hiệu cảnh báo sớm cho các cán bộ y tế ra quyết định.

Mục tiêu cụ thể là sử dụng hợp nhất dữ liệu đa nền tảng ở cấp thành phố (geocode) theo tuần dịch tễ (epiweek) xây dựng nút (node) – thành phố (geocode) và cạnh (edge) – liên kết địa lý hoặc liên kết hành chính. Định lượng mức độ bất thường và xu hướng thông qua báo cáo gat_global_weekly_report.csv theo tuần và năm qua không gian log – transform và không gian thật về các chỉ số sai số tuyệt đối trung bình giữa dự báo và giá trị thật (MAE), sai số bình phương trung bình (RMSE), tỉ lệ phân trăm sai số đối xứng (SMAPE), Tỉ lệ biến thiên dữ liệu thực được mô hình giải thích (R^2) và sử dụng R^2 trim như một biến thể loại bỏ các điệm ngoại lai trước khi tính toán giúp phản ánh năng lực mô hình trong tình huống dữ liệu ổn định và không bị outlier.

1.2. Nền tảng dữ liệu

1.2.1. Dữ liệu bệnh sốt xuất huyết - Dengue cases

Bộ dữ liệu dịch tễ bệnh sốt xuất huyết được sử dụng từ Mosqlimate – một nền tảng cung cấp thông tin dịch tễ chuẩn hóa theo không gian - thời gan cụ thể ở đây là địa phương (geocode) và theo tuần (epiweek) tại Brazil [1].

Dữ liệu bệnh sốt xuất huyết được tổ chức từ năm 2010 đến 2024 dưới dạng tập trung (big dataset) dung lượng lớn khó nạp dữ liệu. Trong quá trình tiền xử lý và thuận lợi cho việc tiến hành quản lý và nạp dữ liệu, dữ liệu gốc được tách thành 15 tệp theo từng năm với quy tắc đặt tên thống nhất với cấu trúc dengue_year.csv:

- Dengue_2010.csv
- Dengue_2011.csv
- …
- Dengue_2024.csv

Trong đó mỗi tập con (theo năm) vẫn giữ nguyên cấu trúc gốc đảm bảo tính nhất quán và khả năng tái sử dụng:

date	year	epiweek	casos	geocode	regional	regional_geocc	macroregional	macroregi	uf	train_1	train_2	target_1	target_2	epiyear
01/03/2010	2010	201001	0	4208450	Nordeste	42011	Planalto Norte e N	4211	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4216206	Nordeste	42011	Planalto Norte e N	4211	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4218509	Meio Oeste	42008	Meio Oeste e Serra	4212	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4216404	Extremo Sul Catar	42014	Sul	4210	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4201307	Nordeste	42011	Planalto Norte e N	4211	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4204178	Serra Catarinens	42013	Meio Oeste e Serra	4212	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4219358	Alto Vale do Itaja	42004	Alto Vale do ItajaÃ	4216	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4206405	Extremo Oeste	42001	Grande Oeste	4213	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4207700	Alto Uruguai Cata	42010	Meio Oeste e Serra	4212	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4203907	Meio Oeste	42008	Meio Oeste e Serra	4212	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4205555	Alto Vale do Rio c	42009	Meio Oeste e Serra	4212	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4215679	Alto Vale do Itaja	42004	Alto Vale do ItajaÃ	4216	SC	TRUE	TRUE	FALSE	FALSE	2010
01/03/2010	2010	201001	0	4215109	MÃ©dio Vale do I	42006	Alto Vale do ItajaÃ	4216	SC	TRUE	TRUE	FALSE	FALSE	2010

Bảng 1.1: Dengue_2010.csv

Cấu trúc gốc với nhiều trường thông tin như date, geocode, regional, macroregional, uf, các biến mặt nạ (train_1, target_1), và epiyear phục vụ nhiều loại phân tích dịch tễ khác nhau nhưng để xử lý và nạp cho mô hình chỉ sử dụng 4 thông tin cốt lõi để trích xuất bao gồm:

- Geocode: mã địa phương (7 ký tự).
- Year: năm dịch tễ.
- Epiweek: tuần dịch tễ (thông thường 1 – 52).
- Casos: số ca mắc mới trong tuần.

Cách này bao quát hết không gian và thời gian đầy đủ theo tuần và địa phương trực tiếp vào mô hình thông qua biến mục tiêu (số ca bệnh). Qua đó giảm tải dữ liệu dư thừa và khó xử lý, tăng hiểu quả tính toán chỉ dựa vô những thông tin cốt lõi để xây dựng và huyến luyện đồ thị.

1.2.2. Dữ liệu khí hậu – Climate

Kế tiếp dự án cũng sử dụng tập dữ liệu từ Mosqlimate [1] - khí hậu tương tự cấu trúc bệnh sốt xuất huyết như bao phủ toàn bộ giai đoạn năm 2010 đến 2024 được tổ chức phản ánh đầy đủ chi tiết các yếu tố khí tượng chuẩn có ảnh hưởng đến bệnh sốt xuất huyết. Về tệp gốc là duy nhất nhưng bản thân cũng đã chia thành nhiều tệp con theo năm tương tự dữ liệu sốt xuất huyết. Tệp có dữ liệu gốc là về hằng ngày (daily time series), bao gồm nhiều trường thông tin như nhiệt độ, lượng mưa, độ ẩm tương đối, áp suất khí quyển, biên độ nhiệt và số ngày mưa chia thành tệp con với cấu trúc climate_year.csv:

- Climate_2010.csv
- Climate_2011.csv
- …
- Climate_2024.csv

date	epiweek	geocode	temp_min	temp_mec	temp_ma	precip_mi	precip_me	precip_ma	precip_tot	pressure_	pressure_	pressure_	rel_humid	rel_humid	rel_humid	thermal_r	rainy_day	year
01/03/2010	201001	1100015	22.4757	25.051	28.7542	0.0057	0.3322	1.4422	2.6578	0.9937	0.9963	0.9986	75.5274	90.2972	98.8605	6.2786	7	2010
01/03/2010	201001	1100023	22.9026	25.7522	29.9434	0.0024	0.2774	1.0503	2.219	0.9933	0.996	0.9985	70.9279	88.3983	98.8409	7.0409	7	2010
01/03/2010	201001	1100031	22.7202	25.9932	30.2874	0.0047	0.4134	1.9854	3.3069	0.9931	0.9958	0.998	67.5807	86.1613	97.3526	7.5672	7	2010
01/03/2010	201001	1100049	22.6704	25.1289	28.7473	0.0002	0.4624	1.9635	3.699	0.9936	0.9962	0.9986	75.8154	90.5637	98.522	6.0769	7	2010
01/03/2010	201001	1100056	22.7377	25.8794	30.0369	0.0056	0.3755	1.6618	3.0041	0.9932	0.9959	0.998	68.9307	86.7191	96.9561	7.2992	7	2010
01/03/2010	201001	1100064	22.4303	25.4207	29.2661	0.0198	0.2874	1.1357	2.2992	0.9935	0.9961	0.9982	71.0419	87.2873	96.5412	6.8358	7	2010
01/03/2010	201001	1100072	22.3846	25.3439	29.1833	0.012	0.2449	1.1158	1.9591	0.9935	0.9961	0.9983	72.2004	88.1974	97.213	6.7987	7	2010
01/03/2010	201001	1100080	24.3693	26.8637	30.4421	0.0004	0.3314	2.0041	2.6509	0.9922	0.9952	0.9977	68.4516	84.5259	93.48	6.0728	7	2010
01/03/2010	201001	1100098	22.5571	25.1178	28.7467	0.0005	0.4211	1.7732	3.369	0.9937	0.9962	0.9985	75.8959	90.3281	98.7763	6.1896	7	2010
01/03/2010	201001	1100106	23.9817	26.8545	30.905	0.0026	0.2264	1.1389	1.8109	0.9921	0.9953	0.998	68.2724	85.0921	95.2771	6.9233	7	2010

Bảng 1.2: Climate_2010.csv

Giữ nguyên cấu trúc gốc tất cả các trường thông tin như date, epiweek, geocode, các temp_min, temp_med, temp_max, precip_min, precip_med, precip_max, precip_tot, pressure_min, pressure_med, pressure_max, rel_humid_min, rel_humid_med, rel_humid_max, thermal_range, rainy_days, year.

Trong khuôn khổ đồ án này, chỉ lấy các trường cần thiết để dữ liệu đầu vào được ổn định và giảm nhiều bao gồm:

- Geocode: mã địa phương (7 ký tự).
- Year: năm dịch tễ.
- Epiweek: tuần dịch tễ (thông thường 1 – 52).
- Nhiệt độ trung bình tuần (temp_med).
- Tổng lượng mưa tuần (precip_tot).
- Số ngày mưa trong tuần (rainy_days).
- Độ ẩm tương đối trung bình tuần (rel_humid_med).

1.2.3. Dữ liệu dân số xã hội - Population

Dữ liệu dân số sử dụng từ dự án Mosqlimate thông qua Viện Địa lý và Thống kê Brazil (IBGE) cung cấp [1]. Tệp dữ liệu gốc IBGE_POPTCU.csv có cấu trúc gồm 3 trường:

- MUNIC_RES: mã địa phương tương đồng giá trị trường geocode (7 ký tự).
- ANO: Năm quan sát rộng từ năm 1992 đến 2024 tương tự trường year.
- POPULACAO: Dữ liệu dân số cho từng địa phương được công bố chính thức.

Nhưng với đồ án, chúng ta sẽ sử dụng tệp dữ liệu gốc chỉ lấy từ năm 2010 đến năm 2024 để khớp dữ liệu. Ở các năm 2022, 2023 không được công bố chính thức mà chỉ công bố năm 2024 nên sẽ sử dụng phương pháp nội suy (nearest year imputation) từ năm lân cận gần nhất, không tính trung bình để đảm bảo tính liên tục và nhất quán chuỗi thời gian trong bước xây dựng và nạp dữ liệu. Nếu tính trung bình sẽ gây ra trượt gây lệch số liệu thực và ước lượng dẫn đến sai bài toán, ảnh hưởng toàn bộ tính lịch sử.

MUNIC_RES	ANO	POPULACAO
1100015	1992	34768
1100023	1992	61737
1100031	1992	8633
1100049	1992	72462
1100056	1992	23280
1100064	1992	27830
1100072	1992	13317
1100080	1992	10617
1100098	1992	24630
1100106	1992	33783
1100114	1992	52287
1100122	1992	102481
1100130	1992	17202
1100148	1992	16317
1100155	1992	55496
1100189	1992	51784
1100205	1992	284576
1100254	1992	31981
1100262	1992	4830
1100288	1992	46703
1100296	1992	12848
1100304	1992	40249

Bảng 1.3: IBGE_POPTCU.csv

1.2.4. Dữ liệu môi trường sinh thái quần xã – Biome

Dữ liệu từ môi trường sinh thái được tổ chức về những quần xã đặc thù tại Brazil. Thể hiện sự đa dạng sinh học và các điều kiện khác biệt giữa các vùng trên cả nước. Trong đó, dự án Mosqlimate cung cấp dữ liệu môi trường sinh thái vốn dựa trên cơ sở sinh thái công bố chính thức của Viện Địa lý và Thống kê Brazil (IBGE). Các thông tin gắn cho từng địa phương (geocode), nhằm thể hiện nền tảng sinh thái đa ngữ cảnh, nền tảng phục vụ phân tích.

- Geocode: mã địa phương (7 ký tự).
- Name_muni: tên địa phương.
- Biome: môi trường quần xã sinh thái đặc thù bao gồm: Amazonia, Cerrado, Caatinga, Mata Atlântica, Pampa, Pantanal.
- Altitude: độ cao so với mực nước biển.
- Koppen: ký hiệu loại khí hậu.

geocode	name_muni	biome	altitude	koppen
1100015	ALTA FLORESTA I	amazonia	246.08	Am
1100023	ARIQUEMES	amazonia	165.9	Am
1100031	CABIXI	amazonia	224.18	Am
1100049	CACOAL	amazonia	229.95	Am
1100056	CEREJEIRAS	amazonia	192.22	Am
1100064	COLORADO DO (	amazonia	359.62	Am
1100072	CORUMBIARA	amazonia	266.89	Am
1100080	COSTA MARQUE	amazonia	190.01	Am
1100098	ESPIGÇO D'OEST	amazonia	296.94	Am
1100106	GUAJARµ-MIRIM	amazonia	197.96	Am
1100114	JARU	amazonia	209.76	Am
1100122	JI-PARANµ	amazonia	193.68	Am
1100130	MACHADINHO D	amazonia	136.83	Am
1100148	NOVA BRASIL¶N	amazonia	249.3	Am
1100155	OURO PRETO DC	amazonia	220.01	Am
1100189	PIMENTA BUENC	amazonia	286.28	Am
1100205	PORTO VELHO	amazonia	120.26	Am
1100254	PRESIDENTE MD	amazonia	210.79	Am
1100262	RIO CRESPO	amazonia	153.27	Am
1100288	ROLIM DE MOUR	amazonia	242.23	Am
1100296	SANTA LUZIA D'C	amazonia	341.63	Am
1100304	VILHENA	amazonia	409.37	Am
1100320	SÇO MIGUEL DO	amazonia	236.82	Am
1100338	NOVA MAMOR	amazonia	205.24	Am
1100346	ALVORADA D'OE	amazonia	248.65	Am
1100379	ALTO ALEGRE DC	amazonia	255.49	Am
1100403	ALTO PARAÖSO	amazonia	134.69	Am
1100452	BURITIS	amazonia	170.1	Am

Bảng 1.4: Environ_vars.csv

1.2.5. Dữ liệu bản đồ và liên kết hành chính

Liên kết hành chính lấy từ dự án Mosqlimate bởi Viện Địa lý và Thống kê Brazil (IBGE) [1]. Một trong những cốt lõi của dự án về liên kết hành chính thống nhất để làm nền tảng tạo cạnh liên kết và bản đồ. Ban đầu tệp gốc regic2018.csv có các trường geocode;UF;name_muni;hierarquia nhưng dính liền tạo thành 1 trường duy nhất không thể hiện sự liên kết khó quản lý và nạp dữ liệu nên đã tách ra từng trường riêng biệt thể hiện sự liên kết vượt trội.

- Geocode: mã địa phương (7 ký tự).
- UF: Ký hiệu bang.
- Name_muni: tên địa phương.
- Hierarquia: bậc địa phương.

geocode;UF;name_muni;hierarquia
3550308;SP;Arranjo Populacional de São Paulo/SP;Grande Metrópole Nacional
3304557;RJ;Arranjo Populacional do Rio de Janeiro/RJ;Metrópole Nacional
5300108;DF;Arranjo Populacional de Brasília/DF;Metrópole Nacional
3106200;MG;Arranjo Populacional de Belo Horizonte/MG;Metrópole
4314902;RS;Arranjo Populacional de Porto Alegre/RS;Metrópole
4106902;PR;Arranjo Populacional de Curitiba/PR;Metrópole
3509502;SP;Arranjo Populacional de Campinas/SP;Metrópole
2927408;BA;Arranjo Populacional de Salvador/BA;Metrópole
2611606;PE;Arranjo Populacional do Recife/PE;Metrópole
2304400;CE;Arranjo Populacional de Fortaleza/CE;Metrópole
1302603;AM;Manaus;Metrópole
5208707;GO;Arranjo Populacional de Goiânia/GO;Metrópole
3205309;ES;Arranjo Populacional de Vitória/ES;Metrópole
1501402;PA;Arranjo Populacional de Belém/PA;Metrópole
4205407;SC;Arranjo Populacional de Florianópolis/SC;Metrópole
3543402;SP;Arranjo Populacional de Ribeirão Preto/SP;Capital Regional A
2111300;MA;Arranjo Populacional de São Luís/MA;Capital Regional A
2408102;RN;Arranjo Populacional de Natal/RN;Capital Regional A
5103403;MT;Arranjo Populacional de Cuiabá/MT;Capital Regional A
5002704;MS;Campo Grande;Capital Regional A
2507507;PB;Arranjo Populacional de João Pessoa/PB;Capital Regional A

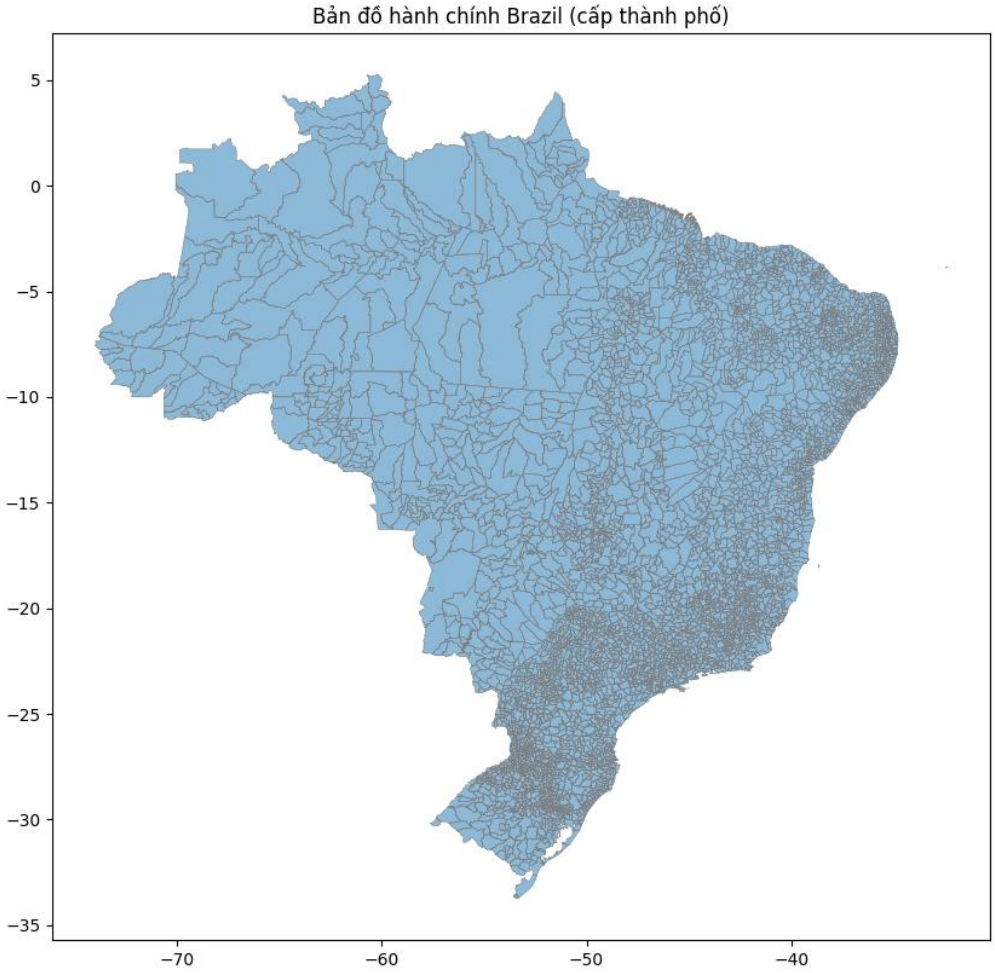
Bảng 1.5: Regic2018.csv

Sau khi tách ra từng trường riêng biệt thì dễ dàng quản lý và nạp dữ liệu danh chóng.

geocode	UF	name_muni	hierarquia
3550308	SP	Arranjo Populacional de São Paulo/S	Grande Metrópole Nacional
3304557	RJ	Arranjo Populacional do Rio de Jane	Metrópole Nacional
5300108	DF	Arranjo Populacional de Brasília/DF	Metrópole Nacional
3106200	MG	Arranjo Populacional de Belo Horizo	Metrópole
4314902	RS	Arranjo Populacional de Porto Alegre	Metrópole
4106902	PR	Arranjo Populacional de Curitiba/PR	Metrópole
3509502	SP	Arranjo Populacional de Campinas/S	Metrópole
2927408	BA	Arranjo Populacional de Salvador/BA	Metrópole
2611606	PE	Arranjo Populacional do Recife/PE	Metrópole
2304400	CE	Arranjo Populacional de Fortaleza/C	Metrópole
1302603	AM	Manaus	Metrópole
5208707	GO	Arranjo Populacional de Goiânia/GC	Metrópole
3205309	ES	Arranjo Populacional de Vitória/ES	Metrópole
1501402	PA	Arranjo Populacional de Belém/PA	Metrópole

Bảng 1.6: Regic2018_clean.csv

Để thể hiện đặc điểm không gian ở các địa phương Brazil, đồ án sử dụng file geojs-100-mun.json có bản đồ không gian địa phương và vùng ranh giới. Tệp dữ liệu này được chuyển đổi và công bố bởi Viện Địa lý và Thống kê Brazil (IBGE) [3], làm bản đồ hành chính tại Brazil không bao gồm được cung cấp trong dự án Mosqlimate nhưng có thể sử dụng làm bổ trợ chi tiết.



Hình 1.1: Bản đồ hành chính Brazil (cấp thành phố)

Các trường có trong tệp dữ liệu bao gồm: 5564 thành phố

- Id: tương tự giá trị như trường geocode bao gồm 7 ký tự.
- Name: tên địa phương.
- Description: mô tả địa phương thường trùng với name dùng để thể hiện tương tác
- Geometry: đa giác biểu diễn vùng và ranh giới thành phố chuẩn tọa độ WGS84 (EPSG:4326).

Mẫu dữ liệu:

	id	name	description	geometry
0	1100015	Alta Floresta D'Oeste	Alta Floresta D'Oeste	POLYGON ((-62.18209 -11.86686, -62.1623 -11.87...
1	1100023	Ariquemes	Ariquemes	POLYGON ((-62.53595 -9.73182, -62.50782 -9.754...
2	1100031	Cabixi	Cabixi	POLYGON ((-60.3994 -13.45584, -60.40195 -13.46...
3	1100049	Cacoal	Cacoal	POLYGON ((-61.00051 -11.39796, -61.01794 -11.4...
4	1100056	Cerejeiras	Cerejeiras	POLYGON ((-61.50047 -13.00392, -61.47901 -13.0...

Bảng 1.7: geojs-100-mun.json

1.3. Khảo sát sơ bộ

Thông qua tất cả các nền tảng dữ liệu thu thập và sử dụng khác nhau nhưng đều có những đặc điểm:

- Định danh đều bằng mã 7 ký tự (chữ số), đều có cột geocode và tương đương như MUNIC_RES, id đều có cùng giá trị mã địa phương có thể làm khóa chính chung dẫn dắt và liên kết tất cả dữ liệu và xây dựng một cách có hệ thống và nhất quán liên tục làm không gian (spatio).
- Cấu trúc thời gian cũng liên tục và đầy đủ đều bắt nguồn theo chuẩn năm và tuần (year, epiweek) từ tuần 1 đến tuần 52 (temporal).
- Bao phủ toàn bộ lãnh thổ Brazil bao gồm 5564 đơn vị hành chính đảm bảo tính thống nhất và toàn vẹn lý luận làm tiền đề huấn luyện và trực quan. Không tách biệt đô thị lớn mà còn chỉ ra các vùng nông thôn, liên kết toàn bộ lãnh thổ.
- Nền tảng dữ liệu từ đồ án được bổ sung đa dạng từ dịch tễ đến cả khí hậu, bao gồm dân số, biến môi trường bổ trợ và liên kết hành chính và không gian bản đồ làm khung cạnh liên kết giữa các địa phương.
- Sự nhất quán cho phép kết hợp tất cả dữ liệu điều xây dựng nên đồ thị mạng lưới cụ thể và liên kết tương quan cho mô hình Spatio-temporal Graph Neural Networks:
  1. Nút (node) = địa phương.
  2. Cạnh (edge) = quan hệ không gian (liên kết hành chính, liên kết tiếp giáp) và mạng lưới.
  3. Đặc trưng node = các trường thông tin như khí hậu, dân số, hệ sinh thái, số ca bệnh

Đây là điều kiện cần và đủ để triển khai một mô hình cao cấp để dự đoán và trực quan.

1.4. Góc nhìn bổ sung từ phỏng vấn sâu chuyên gia – Bác sĩ

Trong quá trình triển khai nghiên cứu khoa học, thì đồ án này được kế thừa những giá trị từ buổi phỏng vấn sâu từ chuyên gia – Bác sĩ từ phòng chỉ đạo tuyến thuộc Bệnh viện Nhiệt Đới Thành Phố Hồ Chí Minh chia sẽ những góc đồ thực tiễn định hướng cho nghiên cứu:

Các chuyên gia nói rằng không chỉ dùng số ca bệnh mà còn lí luận theo mật độ dân cư và nghề nghiệp đại diện cùng khu vực sinh sống sẽ ảnh hưởng đến quá trình biến động

dịch bệnh khác nhau cũng như khu công nghiệp, lượng mưa lớn hay nước đọng ao tù hay kề những khu vực có sông ngoài kênh rạch đều có tỉ lệ mắc bệnh cao hơn những khu vực thông thường. Ở đây có thể kể đến hành vi xã hội nhưng cần phải có một nghiên cứu sâu về hành vi xã hội làm nền tảng từ trước, nên sẽ không sử dụng hành vi xã hội thay vào đó sử dụng khu vực và khí hậu làm nhân tố chính, bao gồm khu vực dịch tễ và khu vực liền kề sẽ đáng xem xét nhất và các thành phố có cùng cấp sẽ cũng sẽ có tình trạng gần như tương quan hoặc mức di chuyển sinh sống liên kết.

Khí hậu gần như là về chỉ số ngày mưa và lượng mưa, nhiệt độ trung bình 25–30°C được xem là khoảng thuận lợi cho vòng đời muỗi được rút ngắn dẫn đến tốc độ sinh sản tăng cao cho chu kỳ lây truyền bệnh sốt xuất huyết. Mọi yếu tố khí tượng còn lại như áp suất khí quyển,độ ẩm tốc độ gió đều chỉ bổ trợ cho các chỉ số chính trên hoặc dẫn đến ngày mưa.

Các bác sĩ có một kỳ vọng về một mô hình không chỉ dự báo số ca bệnh chung mà còn có thể bắt được chu kỳ 4 năm xuất hiện một trận dịch bệnh nguy cơ lớn khó kiểm soát dẫn đến quá tải. Việc khoan vùng (cluster) những điểm nóng (hotspots) để hỗ trợ các bộ nhân viên y tế có thể ra chiến lược hoặc phương pháp xử lý là cần thiết và đáp ứng cho nhu cầu cộng đồng xã hội. Nhận định này hoàn toàn đánh giá mô hình cách tiếp cận Graph Neural Network/Temporal-GAT theo không gian (giữa địa phương) và thời gian (tuần dịch tễ) là thiết thực cho bài toán Bệnh sốt xuất huyết hơn hẳn các bài toán về bệnh như Covid-19, HIV-AIDS vì tính đặc thù theo chuyên gia.

Theo các bác sĩ lẫn các cơ quan y tế, việc công bố ngắn hạn ở mức theo tuần là hữu ích nhất cho công tác phòng chống dịch bệnh. Nếu dự báo theo ngày thì quá ngắn đến gây nhiễu loạn thông tin hoặc không chính xác cao. Theo tháng hoặc năm thì lại bỏ lỡ thời điểm can thiệp kịp thời hoặc công tác xử lý bị chậm trễ. Vì vậy, đồ án sử dụng theo tuần (epiweek) là hợp lý cho y tế lẫn việc công bố phòng chống. Trực quan hóa theo bản đồ và nhiệt (heatmap) cùng với các cách trực quan dashboard để các cán bộ y tế không chuyên công nghệ sẽ dễ dàng sử dụng và điều chỉnh.

Một số loại dữ liệu có thể tuy tiềm năng để thu thập cải thiện độ chính xác nhưng không thể thu thập hoặc khó sử dụng triển khai trong thực tế vì nguyên tắc đạo đức Y học và chi phí quá cao phi thực tế:

- Số lượng muỗi hay mật độ muỗi: Việc bắt và kiểm soát số lượng ở từng địa phương là phi thực tế và khó cho triển khai, khó duy trì thường xuyên ở một quy mô lớn hay các khu vực khác nhau.
- Dữ liệu huyết học bao gồm nhóm máu thì liên quan đến mẫu của bệnh nhân, gây tiết lộ thông tin vi phạm lợi ích và quyền lợi cá nhân bệnh nhân ảnh hưởng đến nguyên tắc đạo đức trong Y học vì bắt buộc phải xin phép và có giấy xác nhận, dữ liệu huyết thanh bệnh sốt xuất huyết như DEN-1, DEN-2, DEN-3 và DEN-4 thì vượt qua kinh phí lớn để có thể xét nghiệm chính xác cho 1 người trên 1 xét nghiệm và vẫn phạm quy tắc tiết lộ thông tin bệnh nhân chưa được xin phép nên vượt ngoài phạm vi đồ án.
- Thông tin cá nhân chi tiết như địa chị củ thể chính xác lại xâm phạm quyền riêng tự bệnh nhân, trái với nguyên tắc bảo mật dữ liệu y tế.
- Vì vậy đồ án này chỉ bao gồm các dữ liệu đã được công khai và chuẩn hóa theo chuẩn Y tế đã công bố để có thể tuân thủ đúng chuẩn mực đạo đức y học và sự bổ trợ .

1.5. Thiết kế nút (node) và đặc trưng (feature & label) gốc và bổ sung

Sau khi khảo sát sơ bộ về mặt dữ liệu đa nền tảng, ta có thể thiết kế nút và đặc trưng gốc và bổ sung với đa dạng góc nhìn từ nhiều nguồn dữ liệu. Mỗi nút (node) trong đồ thị sẽ gắn liền với một địa phương (geocode 7 chữ số). Tập đặc trưng khả biến bao gồm biến gốc và biến suy diễn (engineered features):

Thông tin định danh & khóa chính:

- Geocode: mã địa phương theo chuẩn IBGE, đồng giá trị munic_res, id (7 ký tự) làm không gian (spatial).
- Year, epiweek: năm và tuần dịch tễ học, bảo đảm tính liên tục thời gian (temporal).

Dữ liệu dịch tễ học bệnh sốt xuất huyết:

- Casos: Số ca mắc sốt xuất huyết được báo cáo ghi nhận (số ca).

Đặc trưng khí hậu:

- Temp_med: nhiệt độ trung bình (°C).
- Precip_tot: tổng lượng mưa (mm).
- Rainy_days: số ngày có mưa.(số ngày).
- Rel_humid_med: độ ẩm trung bình (%).

Đặc trưng dân số & xã hội:

- POPULACAO: dân số theo địa phương trong năm (người).
- Altitude: độ cao so với mực nước biển (m).
- Area_km2: diện tích địa phương (km^2).
- Population_density: mật độ dân số (người/km^2).

Đặc trưng môi trường sinh thái & quần xã:

- Name_muni: tên địa phương.
- Biome: môi trường quần xã.
- Koppen: phân loại khí hậu theo hệ thống ký tự Köppen.

Biến bổ sung từ kỹ thuật tạo đặc trưng (engineered features):

1. Incidence_per_1k: số ca mắc trên 1.000 dân theo PAHO [4].

$$Incidence_per1k = \frac{Casos}{POPULACAO} \times 1000$$

2. Humid_heat_index: chỉ số kết hợp nhiệt độ – độ ẩm [5].

$$Humid_heat_index = \frac{Temp_med \times RelHumid_med}{100}$$

3. Precip_std_roll3: độ lệch chuẩn của lượng mưa trong 3 tuần [6].

$$Precip_std_roll3 = Std(Precip_tot^{(t-2:t)})$$

4. Dry_spell_len: số ngày khô hạn trong tuần [7].

$$Dry_spell_len = 7 - Rainy_days$$

5. Incidence_lag1: độ trễ dịch tễ 1 tuần trước (Incidence lag-1) [8].

$$Incidence_lag1 = Incidence_per1k, prev$$

6. Neighbor_cases_prev1: số ca mắc ở các địa phương lân cận trong tuần trước [9].

$$Neighbor_cases_prev1(i,t) = \sum_{j \in Neighbors(i)} Casos(j, t-1)$$

   - i : khu vực đang xem xét (geocode).
   - t : tuần dịch tễ hiện tại.
   - $j \in Neighbors(i)$: tập các khu vực lân cận trực tiếp với i.
   - $Casos(j, t-1)$: số ca bệnh ở khu vực j trong tuần trước $(t-1)$.

Chương 2. XÂY DỰNG VÀ HUẤN LUYỆN GRAPH ATTENTION NETWORKS Ở BỆNH SỐT XUẤT HUYẾT

2.1. Khởi tạo cạnh & nút – edge &node

2.1.1. Mục tiêu

Với các mô hình nền tảng có Graph Neural Networks (GNNs), cấu trục cạnh (edge) đóng vai trò liên kết quan hệ giữa các nút (node) trong việc xác định mối liên hệ không gian vùng lân cận. Với bài toán bệnh sốt xuất huyết, cạnh sẽ thể hiện sự lan truyền bệnh phản ánh liên kết địa lý xung quanh và mức độ tương quan giữa các đơn vị hành chính. Vì vậy thông qua khảo sát, xây dựng đồ thị không gian ở cấp đô thị (municipality) của Brazil để làm đầu vào cho mô hình Graph Attention Networks (GATs). Nút (node) sẽ đại diện một đô thị (nhận diện bởi geocode 7 chữ số hoặc tương đương giá trị như id, munic_res) và cạnh (edge) thể hiện sự liên kết theo vùng và cấp hành chính qua đó tạo nền tảng quan hệ không gian, khai thác cấu trúc địa lý và lan truyền thông tin dịch tễ. Có mục đích là tạo ra từng "ảnh chụp" (snapshot) một tuần – toàn quốc gồm: ma trận đặc trưng X, nhãn y (số ca), và đồ thị không gian kế thừa từ Mục 2.1, dữ liệu này là đầu vào thống nhất cho các mô hình GNN/GAT trong phần thực nghiệm và chuẩn hóa.

2.1.2. Dữ liệu đầu vào & tiền xử lý

- Ranh giới vùng: geojs-100-mun.json (GeoJSON cấp đô thị).

Kiểm tra sơ bộ trước khi nạp dữ liệu là cột id phải tồn tại đại diện duy nhất và chuẩn hóa đồng giá trị chuỗi 7 ký (zeoro-padding) tương đương geocode để đồng bộ nền tảng dữ liệu.

- Liên kết hành chính và cấp đô thị: regic2018_clean.csv

Được sử dụng để hỗ trợ và kiểm tra, đảm bảo tính toàn vẹn và khớp hoàn toàn mã đô thị (geocode) đến cấu trúc hành chính từ IBGE.

Bởi 2 tệp dữ liệu, dữ liệu nút (node) được tạo và tiền xử lý:

- Sinh danh sách nút từ id : all_nodes = sorted(unique(id)).
- Tạo ánh xạ (mapping) để node2idx = {geocode → index 0..N-1} chuẩn hóa và lưu thành tệp data/processed/node2idx.json thống nhất pipeline.
- Đảm bảo sự toàn vẹn và hợp lệ thông qua loại bỏ các polygon rỗng hoặc lỗi.

2.1.3. Phương pháp khởi tạo cạnh – edge

Đầu tiên tạo cạnh tiếp giáp hành chính - Queen contiguity:

Lí luận hai đô thị được nối với nhau nếu vùng lân cận tiếp xúc và kề nhau (đa giác của chúng tiếp xúc, kể cả chỉ một điểm biên) thông qua Queen adjacency, bao quát hơn Rook ở điểm tiếp xúc biên.

- Sử dụng spatial index (sindex) để lấy tập ứng viên theo hộp bao (bounding box).
- Với mỗi cặp ứng viên, kiểm tra intersects. Nếu đúng → thêm cạnh.
- Chuẩn hóa cạnh dưới dạng vô hướng (min(u,v), max(u,v)) để tránh trùng lặp.
- Loại bỏ self-loop (u = v).

Thứ hai bổ sung liên kết K-Nearest Neighbors (KNN) cho nút (node) cô lập:

Lí luận rằng một số đô thị không có liên kết vùng quan hệ với nhau như đảo và vùng hẻo lánh dẫn đến nguy cơ bậc nút (node) bằng 0. Qua đó cải thiện liên kết choi nút (node) cô lập.

- Tính centroid (tâm) của từng polygon.
- Dùng KNN (K = 6) trên toàn bộ centroid.
- Với nút có bậc 0, nối đến K láng giềng gần nhất (bỏ chính nó).

Các thư viện hỗ trợ và thực hiện bằng python:

- GeoPandas:
  - Đọc và xử lý dữ liệu không gian từ tệp GeoJSON.
  - Quản lý cột geometry (đa giác ranh giới hành chính).
  - Tạo spatial index (sindex) để tăng tốc tìm kiếm vùng lân cận.
- NumPy:
  - Biểu diễn và tính toán trên mảng tọa độ (centroid).
  - Hỗ trợ thao tác nhanh khi chuẩn bị dữ liệu cho KNN.
- Scikit-learn (NearestNeighbors):
  - Tìm K láng giềng gần nhất (KNN) cho các đô thị bị cô lập.
  - Đảm bảo đồ thị luôn liên thông bằng cách bổ sung cạnh.
- PyTorch:
  - Chuyển danh sách cạnh sang tensor (edge_index) chuẩn của PyTorch Geometric.
  - Lưu dữ liệu ở định dạng .pt để mô hình GNN có thể sử dụng trực tiếp.

2.1.4. Tổng quan:

- Đọc 2 file : geojs-100-mun.json và regic2018_clean.csv
- Sinh danh sách nút (node), ánh xạ(mapping) ra node2idx.json
- Dựng cạnh bằng 2 phương pháp Queen contiguity và K-Nearest Neighbors
- Xuất kết quả ra 3 tệp:
  - edge_list.csv – danh sách cạnh dạng bảng (src, dst).
  - edge_index.pt – tensor [2, E] cho PyTorch Geometric.
  - node2idx.json – ánh xạ geocode → index.

2.1.5. Kết quả:

Sau khi khởi chạy thực nghiệm toàn bộ dữ liệu thông qua tệp buoc1taoedge.py thành công và xem chi tiết hình 3.1 tại phụ lục minh chứng.

- Số nút (N): 5.564 (ứng với số đô thị của Brazil trong GeoJSON).
- Số cạnh (E): khoảng 16.382, bao gồm cả cạnh Queen và các cạnh KNN thêm vào cho nút cô lập.
- Self-loop: 0 (đã loại bỏ).
- Trùng cạnh: không (các cạnh được chuẩn hóa).
- Tệp đầu ra: edge_list.csv, edge_index.pt, node2idx.json.

2.2. Hoàn thiện đặc trưng & nhãn – feature & label

2.2.1. Mục tiêu

Sau khi đã thiết lập không gian đồ thị ở nút – cạnh (node – edge), ta tiến hành khởi tạo ma trận đặc trưng X và Vector nhãn Y theo từng cột mốc thời gian là tuần dịch tễ để làm trục thời gian một chiều (từ quá khứ - hiện tại – tương lai, không xáo trộn) cho đồ thị Graph Attention Networks giúp mô hình học chuỗi thời gian (temporal).

2.2.2. Nạp dữ liệu đầu vào

Tất cả các nền tảng đã khảo sát và thiết kế, mỗi bản ghi đều được chuẩn hóa theo khóa (geocode – year – epiweek) để đảm bảo đồng bộ giữa các nguồn dữ liệu.

- Dịch tễ: các tập dengue_*.csv (2010–2024), gồm số ca bệnh (casos) theo geocode, year, epiweek.
- Khí hậu: tập climate_*.csv, giữ lại 4 biến chính: nhiệt độ trung bình (temp_med), tổng lượng mưa (precip_tot), số ngày mưa (rainy_days), và độ ẩm trung bình (rel_humid_med).
- Dân số: tập IBGE_POPTCU.csv, được ghép vào theo năm gần nhất nếu thiếu dữ liệu trực tiếp.
- Môi trường – xã hội: environ_vars.csv (altitude, biome, Koppen climate, tên đô thị).
- Diện tích đô thị: tính từ tệp bản đồ geojs-100-mun.json.

2.2.3. Bảo toàn chỉ số nút (node):

Các đô thị được mapping ánh xạ cố định bằng node2idx (geocode → index). Thông qua triển khai danh sách ngược idx2node bảo đảm rằng các ma trận đặc trưng và nhãn được sắp xếp thống nhất với cấu trúc cạnh trong edge_index.pt.

2.2.4. Ghép dữ liệu:

Các bảng số liệu ca bệnh và khí hậu được gộp theo khóa (geocode – year – epiweek).

Các thuộc tính có tính chất tĩnh bao gồm dân số, độ cao, diện tích, quần xã, kiểu khí hậu được gán bổ sung theo geocode.

2.2.5. Xử lý điền thiếu và chuẩn hóa:

Số ca bệnh (caosos) thiếu thì điền 0 thông qua fillna(0) vì ghi nhận ca bệnh thực tế trên ghi nhận giấy tờ, nếu điền giá trị trung bình đều gây sai lệch hoặc không phản ánh rõ logic dịch tễ ghi nhận.

Các biến khí hậu (nhiệt độ, mưa, độ ẩm) thiếu thì điền fillna(mean) vì phản ánh sự trung bình đều mang tính địa phương và ổn định theo vùng, đảm bảo tính đặc thù theo không gian và thời gian, tránh làm lệch mất dòng dữ liệu.

Dân số (populacao) thì lấy khả biến dân số gần nhất (nearest) vì dân số số thường lấy dữ liệu đã phát hành chính thức định kỳ (không hàng năm). Do đó, việc dùng năm gần nhất thể hiện rõ ràng và trung thực xu hướng nhân khẩu học. Trường hợp thiếu do lỗi dữ liệu dùng trung vị quốc gia thay thế vì trung bình hoàn toàn giảm tác động của ngoại lệ (outlier) vả không phản ánh rõ ràng trung thực xu hướng tại một địa phương.

Diện tích (area_km²) nếu thiếu thì tính toán lại từ hình học bản đồ (Geojso) do hình học đa giác đảm bảo sự chính xác theo thực địa – địa phương,), không khả dụng thì gán trung vị để tránh lệch do một số đô thị có diện tích cực lớn không thể lấy trung bình sẽ gây sai lệch kết quả ví dụ như Amazonas.

2.2.6. Tạo đặc trưng gốc từ khảo sát và thiết kế:

- Khí hậu: temp_med, precip_tot, rainy_days, rel_humid_med.
- Dân số & môi trường: populacao, altitude, area_km2.

2.2.7. Tạo đặc trưng bổ sung từ khảo sát và thiết kế:

- Mật độ dân số: population_density = POPULACAO / area_km2.
- Tỷ lệ mắc/1.000 dân: incidence_per_1k = (casos / POPULACAO) * 1000.
- Chỉ số nhiệt-ẩm (phiên bản gọn để học máy): humid_heat_index = (temp_med * rel_humid_med) / 100.
- Độ biến thiên mưa 3 tuần: precip_std_roll3 = rolling std(precip_tot, window=3) theo từng geocode (min_periods=2).
- Chuỗi khô: dry_spell_len = clip(7 − rainy_days, 0..7).
- Độ trễ tỷ lệ mắc 1 tuần: incidence_lag1 = incidence_per_1k (tuần trước) theo từng geocode.
- Tổng ca lân cận tuần trước: neighbor_cases_prev1 = tổng casos của tất cả đô thị kề cạnh (theo edge_index) tại tuần trước; xử lý nhảy năm với quy tắc (1→52, year −1).

2.2.8. Chuẩn hóa & chống trùng lặp

Trong quá trình khởi tạo thì mọi rolling/lag đều sort theo (geocode - year – epiweek) để đảm bảo nhân quả thời gian.

Nếu trùng lặp thì khử trùng lặp cuối cùng theo (geocode - year – epiweek)) với quy tắc:

- casos: tính tổng (sum)
- khí hậu/dân số/độ cao/diện tích: các bản trùng thì tính trung bình mean.
- mô tả văn bản (biome/koppen/name):lấy gộp first.

2.2.9. Định nghĩa mặt nạ huấn luyện phân tách theo năm:

- Huấn luyện -Train: 2010–2020.
- Kiểm định - Validation: 2021–2022.
- Đánh giá - Test: 2023–2024.

2.2.10. Tạo đặc trưng – feature

Đặc trưng khí hậu: nhiệt độ trung bình, lượng mưa tuần, số ngày mưa, độ ẩm trung bình.

Đặc trưng tĩnh/dân số: dân số, độ cao, diện tích, mật độ dân số.

Đặc trưng suy diễn: tỷ lệ mắc/1000 dân, chỉ số ẩm–nhiệt, biến động mưa 3 tuần, độ dài chuỗi ngày khô, ca bệnh trễ 1 tuần, tổng ca lân cận tuần trước.

2.2.11. Tạo nhãn – label

Các số ca mắc (casos) theo tuần được làm biến mục tiêu, trường hợp ngoại lệ bản ghi được gán 0 khi không phát hiện ca bệnh, bảo đảm tính liên tục chuỗi thời gian, không lỗ hỏng thời gian.

2.2.12. Kết quả thực nghiệm

Thực thi thành công tập tin buoc2taofeature_label.py ở phụ lục, quan sát rõ có thể thấy những đặc tính sau:

Số lượng nút (N): 5.564 nút, tương ứng với toàn bộ các đô thị (municipalities) của Brazil.

Ma trận cạnh (edge_index): có kích thước (2, 16382), phản ánh 16.382 quan hệ láng giềng địa lý sau khi kết hợp phương pháp Queen contiguity và bổ sung KNN cho các nút (node) cô lập.

Tích hợp dữ liệu nền: hệ thống đã đọc thành công dữ liệu môi trường (environ_vars.csv), dữ liệu dân số (IBGE_POPTCU.csv), dữ liệu dịch tễ (dengue_*.csv) và dữ liệu khí hậu (climate_*.csv).

Xuất dữ liệu trung gian: sinh ra tệp CSV tổng hợp (weekly_features_labels.csv) và các tệp theo năm trong thư mục interim/yearly/, phục vụ kiểm chứng và đối chiếu.

Snapshot cho mô hình học sâu: tổng cộng 760 snapshot ở định dạng .pt được lưu vào processed/weekly_pt. Mỗi snapshot đại diện cho một tuần dịch tễ, gồm ma trận đặc trưng X, vector nhãn Y, ma trận cạnh edge_index, cùng các mặt nạ phân chia train/val/test.

Danh sách đặc trưng (14 biến):

- Khí hậu gốc: temp_med, precip_tot, rainy_days, rel_humid_med.
- Dân số–môi trường: POPULACAO, altitude, area_km2, population_density.
- Đặc trưng suy diễn: incidence_per_1k, humid_heat_index, precip_std_roll3, dry_spell_len, neighbor_cases_prev1, incidence_lag1.

Nhờ cấu trúc thiết kế rõ ràng các khóa, tệp dữ liệu này đều đảm bảo:

- Toàn vẹn thời gian: mỗi tuần đều có bản ghi cho tất cả đô thị, với ca bệnh gán bằng 0 khi không có báo cáo.
- Kết nối không gian: cạnh biểu diễn quan hệ láng giềng giúp mô hình học được cơ chế lan truyền dịch bệnh giữa các khu vực.

2.3. Kiểm tra hiện vật - sanity check

2.3.1. Mục tiêu

Sau khi hoàn thành bước xây dựng đồ thị 2.1 và tạo đặc trưng - nhãn theo tuần ở 2.2, việc kiểm định chất lượng dữ liệu đầu vào đâu ra rất là quan trong để tạo tiền đề cho, chuẩn hóa, biến đổi và huấn luyện thống nhất mạch trật tự. Mục tiêu bước này chính là:

- Đảm bảo tính đầy đủ của các tệp hiện vật (artifacts) đã sinh ra trong pipeline, bao gồm: ánh xạ nút (node2idx.json), danh sách cạnh (edge_index.pt), bộ dữ liệu trung gian (weekly_features_labels.csv và các CSV theo năm), cùng các snapshot huấn luyện (*.pt).
- Kiểm tra hình dạng (shape) và nội dung của các tensor x, y, edge_index để xác nhận rằng chúng đáp ứng chuẩn đầu vào của mô hình GNN.
- Phát hiện sớm các lỗi phổ biến như thiếu cột, NaN/Inf trong đặc trưng, mask chồng chéo hoặc không có dữ liệu trong một số năm.

2.3.2. Phương pháp

Xác thực tệp cốt lõi: bao gồm kiểm tra sự tồn tại của node2idx.json, edge_index.pt, và thư mục chứa snapshot (weekly_pt/). Đọc và khôi phục ánh xạ geocode – Index, xác nhận số lượng nút N và dạng tensor cạnh 2 * E

Đối chiếu dữ liệu bảng (CSV):

geocode	year	epiweek	casos	temp_mec	precip_tot	rainy_day	rel_humid	POPULAC/	altitude	area_km2	name_mu	biome	koppen	populatio	incidence	humid_he	precip_stc	dry_spell_	incidence	neighbor_
1100015	2010	201001	3	25.051	2.6578	7	90.2972	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.12284	22.62035	0	0	0	0
1100015	2010	201002	1	23.9808	5.84	7	92.6972	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.040947	22.22953	2.250155	0	0.12284	350
1100015	2010	201003	1	25.2581	4.0574	7	88.6503	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.040947	22.39138	1.594937	0	0.040947	361
1100015	2010	201004	8	24.4701	2.8026	7	91.8555	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.327573	22.47713	1.526324	0	0.040947	349
1100015	2010	201005	4	25.577	2.5076	7	89.8352	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.163787	22.97715	0.822945	0	0.327573	415
1100015	2010	201006	6	24.8833	3.6589	7	92.1119	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.24568	22.92048	0.59802	0	0.163787	340
1100015	2010	201007	2	24.9777	3.7603	7	91.2383	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.081893	22.78923	0.695825	0	0.24568	274
1100015	2010	201008	1	25.4936	2.1426	7	89.0085	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.040947	22.69147	0.906127	0	0.081893	278
1100015	2010	201009	0	25.3461	4.6336	7	90.3897	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0	22.91026	1.263902	0	0.040947	133
1100015	2010	201010	0	26.0555	2.1825	7	87.8173	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0	22.88124	1.426801	0	0	86
1100015	2010	201011	0	26.1046	1.9755	7	87.6975	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0	22.89308	1.478526	0	0	113
1100015	2010	201012	1	25.5287	3.2757	7	88.5379	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.040947	22.60257	0.698624	0	0	80
1100015	2010	201013	0	24.9718	3.6172	7	91.2578	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0	22.78872	0.866249	0	0.040947	68
1100015	2010	201014	0	24.1219	0.6391	3	77.538	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0	18.70364	1.629794	4	0	39
1100015	2010	201015	0	26.0117	0.0226	2	75.3948	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0	19.61147	1.922251	5	0	48
1100015	2010	201016	0	27.503	0.1242	6	79.7171	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0	21.92459	0.330534	1	0	39
1100015	2010	201017	0	27.2151	0.1577	5	76.9913	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0	20.95326	0.070352	2	0	23
1100015	2010	201018	0	25.7426	1.6843	6	83.5584	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0	21.5101	0.891211	1	0	28
1100015	2010	201019	1	20.8995	0.0102	1	63.5753	24422	246.08	7110.04	ALTA FLOF	amazonia	Am	3.434861	0.040947	13.28692	0.926901	6	0	16

Bảng 2.1 Weekly_2010.csv

Đọc file Weekly_2010.csv và kiểm tra số hàng số cột Kiểm tra sự hiện diện của các cột bắt buộc: geocode, year, epiweek, casos, temp_med, precip_tot, rainy_days, rel_humid_med. Đánh giá phạm vi năm và số tuần dịch tễ để đảm bảo phủ toàn bộ giai đoạn 2010–2024. Xác nhận thư mục yearly/ có chứa tối thiểu một tập CSV tách theo từng năm.

Kiểm định cấu trúc snapshot (.pt): Mở ngẫu nhiên một số tệp snapshot và kiểm tra các khóa bắt buộc: x, y, edge_index, year, epiweek, feature_cols, label_col, geocodes, train_mask, val_mask, test_mask.So khớp kích thước của X(N * F) và Y (N) với số lượng node (nút) thực tế. Xác nhận geocodes khớp thứ tự với node2idx và ba mặt nạ train/val/test không chồng chéo. Phát hiện NaN/Inf trong đặc trưng và nhãn.

Phân tích thống kê mô tả: Sinh thống kê nhanh từ tệp csv, bao gồm min/median/max của các cột trong yếu như caos, incidence_per_1k, population_density, humid_heat_index, neighbor_cases_prev1. Các giá trị cực trị giúp phát hiện điểm bất thường (ví dụ ca bệnh âm, mật độ dân số vô lý).

2.3.3. Kết quả

- Dựa vào hình 2.1 Weekly_2010.csv minh họa:

Cho ta thấy ca bệnh được gán 0 khi không phát hiện, hoàn toàn đảm bảo tính toàn vẹn thời gian. Các đặc trưng khí hậu và nhân khẩu đều xuất hiện đầy đủ, không có giá trị thiếu ở các cột cốt lõi.

- Dựa vào hình 3.3 ở phụ lục Thực Thi buoc2b_check.py minh họa:

Node2idx khởi tạo thành công với 5.564 nút; tensor cạnh có dạng (2, 16.382), phù hợp với đồ thị vô hướng.

Đã tìm thấy 760 snapshot .pt, bao trùm toàn bộ giai đoạn 2010–2024.

File CSV tổng có kích thước (4.231.146, 21), không chứa NaN ở các cột lõi.

Thống kê sanity: số ca bệnh (casos) có giá trị cực đại 48.223 ca/tuần; chỉ số mật độ dân số đạt tối đa ~16.259 người/km²; số ca lân cận tuần trước (neighbor_cases_prev1) đạt cực đại ~57.423. Các giá trị này tuy cao nhưng vẫn hợp lý với quy mô dịch tễ học tại Brazil.

Không phát hiện NaN/Inf trong các tensor đặc trưng và nhãn. Các mặt nạ train/val/test phân tách rõ ràng, không chồng chéo.

- **Kết luận:**

Bước kiểm tra hiện vật (sanity check) xác nhận toàn bộ pipeline từ bước 1 và 2 đã khiến cho ta có bộ dữ liệu hợp lệ, có tính thống nhất và toàn vẹn cao, sẵn sàng cho nhiều bước chuẩn hóa và huấn luyện mô hình Spatial-Temporal Graph Attention Networks

2.4. Chuẩn hóa và biến đổi log - scale & log-transform

2.4.1. Mục tiêu

Sau khi xây dựng các đặc trưng và nhãn theo tuần song song với kiểm định ở bước trên. Việc chuẩn hóa và biến đổi dữ liệu để có thể đưa về các miền giá trì ổn định và quan trọng cho quá trình huấn luyện. Đặc biệt, các mô hình học sâu nền tảng Graph Neural Networks (GNNs) sẽ nhạy cảm với ngoại lệ (outlier), hoặc các thang đo lệch giữa các đặc trưng & nhãn. Qua đó biến số ca mắc bệnh sốt xuất huyết sẽ có phân phối lệch phải và nhiều giá trị, mặc hạn chế đó sẽ được khắc phục bằng đổi log - scale nhằm giảm tác động của outlier và cải thiện tính ổn định trong quá trình tối ưu.

2.4.2. Phương pháp

Trong thực nghiệm, đặc trưng sử dụng Standard Scaling được chọn mặc định, với công thức:

$$x' = \frac{x - \mu}{\sigma}$$

Trong đó μ và σ lần lượt là trung bình và độ lệch chuẩn của từng đặc trưng.

Để đảm bảo tính khách quan, các tham số chuẩn hóa (μ, σ hoặc min,max chỉ được ước lượng trên tập huấn luyện giai đoạn năm 2010 – 2020 để tránh rò rỏ thông tin từ tập kiểm định hay đánh giá (data leakage).

Kế tiếp biến đổi log-scale cho nhãn với công thức:

$$y' = log(1 + y)$$

Biến nhãn casos thông thường có giá trị lớn, phân phối lệch phải nhưng chứa nhiều tuần bằng 0, để biến đổi ta áp dụng công thức phép biến đổi logarit. Phép biến đổi log1p này vừa bảo toàn giá trị 0 vừa chuẩn hóa các giá trị cực đại giảm ảnh hưởng ca bệnh bất thường và hỗ trợ huấn luyện mô hình học được cấu trúc tổng quát.

Tất cả snapshot đầu vào (.pt) từ Bước 2 được đọc lại, chuẩn hóa đặc trưng và áp dụng log-transform cho nhãn.

Kết quả được ghi ra thư mục mới weekly_pt_scaled/, duy trì cùng cấu trúc nhưng thay thế x và y bằng phiên bản đã chuẩn hóa.

Các tham số chuẩn hóa (mean/std hoặc min/max) được lưu trong scaler_weekly.json để thuận tiện cho việc tái lập hoặc áp dụng vào dữ liệu mới.

Thông tin bổ sung về phép biến đổi nhãn (label_transform: log1p) và scaler sử dụng được nhúng vào từng snapshot, bảo đảm khả năng tái hiện quy trình.

2.4.3. Kết quả

Thông qua hình ảnh hực thi tập tin ở phụ lục:

- Số đặc trưng: 14 feature được nhận diện và xử lý đầy đủ.
- Tham số scaler: được lưu trong tệp data/processed/scaler_weekly.json, giúp tái hiện quá trình chuẩn hóa.
- Số snapshot đã xử lý: 760 tệp .pt được scale thành công và lưu tại thư mục data/processed/weekly_pt_scaled.
- Sanity check:
- Ma trận đặc trưng x có kích thước (5564, 14), không chứa giá trị NaN hoặc Inf.
- Vector nhãn y có kích thước (5564,), cũng không có NaN hay Inf.
- Nhãn đã được gắn cờ biến đổi với label_transform=log1p.

Kết quả việc diễn ra chính xác, không gây mất mát hay tạo nên biến ngoại lai hay làm dữ liệu bị thủng, hoàn toàn giữ được dữ liệu toàn vẹn và không mất mát. Đồng thời quá trình lưu tham số Scaler riêng biệt giúp đảm bảo khả năng sử dụng các tập dữ liệu mới trong các nghiên cứu.

2.5. Kiểm tra sau chuẩn hóa và biến đổi

2.5.1. Mục tiêu:

Sau khi dữ liệu dữ liệu đã được chuẩn hóa và biến đổi (scaling – log1p) ở 2.4 thì việc tiến hành một cuộc kiểm tra chất lượng là để đảm bảo các artifact đầu ra (snapshot .pt đã scale) đạt yêu cầu. Bước này như thử nghiệm một vai trò an toàn, thông qua đó phát hiện sớm các lỗi tiềm ẩn trước khi đưa dữ liệu vào huấn luyện mô hình Spatio - temporal Graph Attention Networks.

2.5.2. Quy trình kiểm tra:

Chạy chương trình buoc4_check_scaled.py ở phụ lục minh chứng thực hiện các thao tác kiểm định sau:

- Đọc thông tin ánh xạ và tham số scaler:
  - Tải tệp node2idx.json để khẳng định số lượng nút (N = 5564) và thứ tự node ổn định.
  - Đọc scaler_weekly.json nhằm đối chiếu danh sách đặc trưng đã dùng để scale, bảo đảm tính nhất quán giữa chuẩn hóa và dữ liệu snapshot.
- Duyệt và kiểm định toàn bộ snapshot đã scale:
  - Quét toàn bộ tệp .pt trong thư mục data/processed/weekly_pt_scaled.
  - Xác nhận sự hiện diện của các khóa bắt buộc: x, y, edge_index, year, epiweek, feature_cols, label_col, geocodes, và các mặt nạ (train_mask, val_mask, test_mask).
  - Kiểm tra shape:
    - Ma trận đặc trưng x phải có dạng (N, F), với F đúng bằng số đặc trưng đã scale.
    - Vector nhãn y phải có kích thước (N,).
  - Đối chiếu feature_cols với danh sách trong scaler; cảnh báo nếu không khớp.
  - Kiểm tra geocodes: danh sách mã đô thị trong snapshot phải khớp tuyệt đối với ánh xạ trong node2idx.json.
  - Đảm bảo các mask (train/val/test) loại trừ lẫn nhau, không có trùng lặp.
  - Rà soát giá trị NaN/Inf trong cả đặc trưng và nhãn.
- Báo cáo tổng hợp
    - Toàn bộ kết quả được ghi ra file CSV (check_weekly_pt_scaled_report.csv) trong thư mục data/interim.
    - Ngoài ra, script còn in nhanh thống kê đầu/cuối để người dùng dễ quan sát sanity check.

2.5.3. Kết quả kiểm định:

Kết quả từ chương trình buoc4_check_scaled.py thực nghiệm ở phụ lục như sau:

- Số snapshot: 760 tệp .pt (tương ứng các tuần từ năm 2010–2024) đã được kiểm tra.
- Kết quả tổng hợp: tất cả các snapshot đạt yêu cầu, không phát hiện lỗi nghiêm trọng.
- Sanity check (trích từ log hệ thống):
- node2idx loaded: N=5564
- scaler_weekly.json loaded with 14 features
- Found 760 snapshots in weekly_pt_scaled
- All scaled snapshots look good.
- Kiểm tra ngẫu nhiên: cả snapshot đầu (2010_201) và cuối (2024_202452) đều xác nhận:
- Không có NaN hoặc Inf.

- Mask phân chia chính xác (toàn bộ train cho giai đoạn 2010–2020, val cho 2021–2022, test cho 2023–2024).
- Đặc trưng và geocode khớp chuẩn.

Ý nghĩa kết quả này cho thấy pipeline hoàn toàn mạch lạc và bảo đảm tính toàn vẹn sẵn sàng cho huấn luyện mô hình. Với dữ liệu có độ nhiễu cao, việc tìm và loại bỏ các giá trị thiếu và bất thường xác minh tính đồng bộ thể hiện đặc trưng nút có độ tin cậy cao.

Sẵn sàng cho việc huấn luyện mô hình và phản ánh đúng sự lan truyền bệnh theo không gian và thời gian mà không bị sai lệch bởi lỗi tiền xử lý.

2.6. Khởi tạo kiến trúc mô hình Temporal GAT multi-head

2.6.1. Mô - đun đánh giá — evaluation/metrics.py

Xây dụng mô – đun evaluation/metrics.py để đo lường ổn định cho bài toán hồi quy ca bệnh và thước đo cho số ca bệnh và ngoại lai (outlier) để chuyển hóa thành các chỉ số báo bùng phát nhị phân để tính diện tích dưới đường cong ROC tỉ lệ dương đúng - tỉ lệ dương sai, PR là chỉ số liên quan đến đường cong Precision-Recall.

Chuẩn hoá dữ liệu đầu vào:

- Mọi mảng/tensor được đưa về numpy.float64 một chiều bằng hàm trợ giúp _to_numpy. Cách làm này giúp các phép tính thống kê hoạt động nhất quán dù đầu vào là torch.Tensor hay ndarray.

Khối hồi quy:

- smape_ratio(.): tính SMAPE, ổn định mẫu số bằng epsilon để tránh chia 0.
- robust_r2(.): R^2 bền vững hơn với phương sai rất nhỏ (bảo vệ bởi epsilon).
- trimmed_r2(.): R^2 cắt đuôi (trim) 1% lỗi tuyệt đối lớn nhất nhằm giảm ảnh hưởng outlier dữ liệu dịch tễ.
- evaluate_regression(.): gói chuẩn trả về MAE, RMSE, SMAPE, R^2 trên cùng giao diện.

Khối phân loại từ hồi quy:

- classification_metrics_from_regression(.): biến nhãn thực (miền giá trị thật) thành nhị phân bằng ngưỡng phân vị q (mặc định q=0.90) để mô phỏng "điểm nóng (hotspot) tuần" → tính ROC-AUC và PR-AUC; tự rơi về giá trị trung tính khi dữ liệu một lớp/thiếu bằng thư viện scikit-learn.

Thông qua 2 miền log và miền thực: mô hình huấn luyện trên không gia log-transform (giảm lệch phân phối), khi báo cáo hiệu năng, ta phải có hiện diện log-space (so sánh nội bộ) và real-space (ý nghĩa y tế công cộng). Bộ metric hồi quy ở đây khai thác chung cho cả 2 miền.

SMAPE thì phù hợp dữ liệu có nhiều giá trị nhỏ/0 (dịch tễ theo tuần), giúp so sánh tương quan giữa các đô thị / thời gian.

Trimmed R^2 cắt đuôi giảm nhạy với vài đỉnh bùng phát bất thường (ổ dịch cục bộ hoặc sai số báo cáo), giúp đánh giá năng lực nền của mô hình.

ROC-AUC / PR-AUC từ hồi quy: nhiều quyết định của cán bộ y tế thông thường quan tâm đến phát hiện tuần cao bất thường thay vì sai số tuyệt đối. Suy luận nhị phân bằng ngưỡng phân vị 90% trên số ca thực giúp quy đổi dự báo hồi quy thành tín hiệu cảnh báo sớm mà PR-AUC đặc biệt hữu ích khi tuần cao hiếm gặp (mất cân bằng lớp).

Nếu dữ liệu chỉ có một lớp (toàn "cao" hoặc toàn "thường") hoặc không có scikit-learn, hàm phân loại trả về giá trị trung tính (ROC-AUC=0.5; PR-AUC=pos_rate) thay vì lỗi đảm bảo pipeline không gãy. Mọi phép tính đều dùng NumPy (ổn định số học) và epsilon để tránh chia 0 / phương sai 0.

2.6.2. Kiến trúc mô hình — models/temporal_gat.py

Mô hình trong tệp models/temporal_gat.py gồm hai khối chính:

- TemporalEncoder (mã hoá thời gian, tùy chọn):
  - GRU (batch_first) nhận chuỗi đầu vào dạng [N, T, d_t] (với pipeline hiện tại d_t=1 ví dụ từ các cột *_lag1, *_lagK). GRU trả về dãy ẩn [N, T, H]
  - Multi-Head Self-Attention (PyTorch nn.MultiheadAttention) áp dụng trên chuỗi ẩn để nhấn mạnh các tuần "thông tin" hơn.
  - Gộp bước thời gian cuối: cộng phần tử cuối của GRU và Attention (out [:, -1, :] + attn_out[:, -1, :]) rồi chiếu tuyến tính sang không gian ẩn H. Kết quả là vector thời gian cô đọng t_emb ∈ ℝ^{N×H}
  - Dropout giúp giảm overfitting.
- Spatial GAT block (học tương tác không gian):
  - GATConv #1: đầu vào là đặc trưng tĩnh/khí hậu/nhân khẩu học x ∈ ℝ^{N×F} được ghép với t_emb (nếu bật temporal) sau đó đi qua GAT đa đầu (heads1) . Hàm kích hoạt dùng ELU. Có dropout trên attention.
  - GATConv #2: nén xuống hidden (không concat ở tầng 2), tiếp tục ELU + dropout.
  - Linear(1): suy ra một giá trị hồi quy mỗi nút (log-ca bệnh theo tuần). Hàm forward trả về tensor [N].

Tham số & giá trị mặc định (đi kèm mã):

- TemporalEncoder: hid_dim=64, heads=4, dropout=0.1 .
- Đầu ra: out_dim=1, squeeze về [N].
- Bật/tắt temporal: cờ t_in_dim>0 Với pipeline hiện tại, có cột *_lagK, t_in_dim=1, (chuỗi đơn kênh).

Khi có chuỗi trễ sẽ tạo t_emb và nối theo chiều đặc trưng với x trước khi đi vào GAT. Cách này giữ cho GAT nhìn nhận bối cảnh tức thời (khí hậu/nhân khẩu/dịch tễ tuần hiện tại) và diễn tiến gần đây (từ GRU + Multi-Head Attention).

Khi có độ trễ, mô hình hoạt động như GAT thuần không gian.

Thiết kế quan trọng:

- GRU + Multi-head Attention: GRU tóm tắt động lực ngắn hạn, attention nhấn các tuần then chốt (ví dụ tuần mưa lớn hoặc bùng phát).
- Hai tầng GAT: tầng đầu học trộn thông tin láng giềng qua nhiều kiểu nhìn (multi-head), tầng sau cô đặc thông tin để ổn định dự báo.
- Dropout ở cả temporal và GAT: cân bằng giữa khả năng khái quát và nhiễu dữ liệu thực tế.
- ELU: trơn, ổn định gradient khi đặc trưng đã chuẩn hoá

Độ phức tạp và khả năng chạy trên CPU:

- TemporalEncoder tỉ lệ theo $O(N \cdot T \cdot H)$ (GRU) và $O(N \cdot T^2 \cdot H)$ (attention). Với T nhỏ (số lag hạn chế), chi phí vẫn gọn.
- GAT tỉ lệ theo số cạnh E và số đầu attention, hai lớp giữ cân bằng giữa chất lượng và tốc độ.
- Tổ hợp trên cho phép huấn luyện/đánh giá trên CPU với bộ dữ liệu quốc gia ($N \approx 5.5k$ nút, $E \approx 1.6 \times 10^4$).

Khả năng mở rộng và thay thế:

- Tăng/giảm heads, hidden, hoặc t_hidden để điều chỉnh độ biểu đạt.
- Thay GRU bằng TemporalConv1D/TransformerEncoder khi cần chuỗi dài.
- Bổ sung residual quanh các lớp GAT nếu độ sâu tăng.

Tương thích:

- Đầu vào của TemporalGAT khớp snapshot ở Bước trên bao gồm x (đã scale), edge_index (đồ thị), và temporal_seq (tự xây từ các cột *_lagK).
- Đầu ra [N] là log(1+cases) để khớp với loss/đánh giá và các phép back-transform ở script huấn luyện.

2.6.3. Dựng chuỗi & khởi tạo mô hình — trainers/trainer_weekly.py

Trong hệ thống dự báo dịch tễ dựa trên GNN, ngoài việc xây dựng kiến trúc mô hình (mục 2.6.2), cần có cơ chế huấn luyện để xử lý dữ liệu đầu vào theo từng tuần dịch tễ và tận dụng đặc trưng chuỗi thời gian. Tệp trainer_weekly.py đảm nhận chức năng này. Trong đó có ba thành phần quan trọng gồm: phát hiện phát hiện các biến trễ (lag features), xây dựng chuỗi đầu vào theo tuần, và khởi tạo mô hình Temporal GAT với các siêu tham số thích hợp.

Để mô hình học được nguyên nhân của dịch bệnh, thế nên các thuộc tính quá khứ như số ca mắc trễ 1 tuần (incidence_lag1), lượng mưa tuần trước (precip_lag1) hay nhiệt độ trung bình tuần trước (temp_lag1) được đưa vào. Hàm _find_lag_columns thực hiện việc quét danh sách các đặc trưng và chọn ra các cột có hậu tố _lagK. Các biến này sau đó được sắp xếp theo thứ tự thời gian (lag nhỏ đến lớn), bảo đảm chuỗi có cấu trúc đúng với tiến trình dịch bệnh.

Hàm build_temporal_seq ánh xạ dữ liệu đặc trưng về dạng tensor 3 chiều [N, T, 1], trong đó:

- N: số lượng nút (đô thị),
- T: số bước thời gian (số lag được chọn),
- 1: giá trị của đặc trưng tại mỗi bước.

Điều này cho phép mô hình Temporal GAT tiếp nhận cả thông tin không gian (đồ thị – cạnh) và thông tin thời gian (chuỗi dịch tễ theo tuần).

Hàm make_model cung cấp một cơ chế thống nhất để khởi tạo mô hình Temporal GAT.

Cấu hình mặc định gồm:

- Số chiều ẩn (hidden dimension) là 128,
- Hai lớp GAT liên tiếp với số head lần lượt là 4 và 4,
- Dropout 0.2 để giảm overfitting,
- Khối temporal (GRU + Attention) được bật khi dữ liệu có biến trễ.

Cách thiết kế này giúp mô hình học được liên kết và tương quan không gian giữa các đô thị thông qua cạnh mô hình GAT, vừa khai thác nguyên nhân khởi phát dịch bệnh theo tuần qua GRU–Attention.

2.6.4. Pipeline huấn luyện-đánh giá - run_global_gat.py

Sau khi định nghĩa các mô đun cốt lõi từ mục 2.6.1–2.6.3, bước tổ chức quy trình nạp và huấn luyện toàn cục nằm tận dụng dữ liệu dịch tễ nhiều năm đa nền tảng và đánh giá hiệu năng cao trên các giai đoạn huấn luyện, kiểm định và kiểm thử. Tệp run_global_gat.py đảm nhận vai trò trung tâm trong quá trình này, với các thành phần gồm các tuần snapshot dữ liệu theo tuần được tải từ thư mục đã tiền xử lý. Chúng được phân tách thành ba nhóm như đã đề cập bao gồm:

- Huấn luyện (2010–2020): giúp mô hình học được xu hướng dài hạn.
- Kiểm định (2021–2022): theo dõi hiệu năng và dùng cho cơ chế early stopping.
- Kiểm thử (2023–2024): đánh giá cuối cùng trên dữ liệu hoàn toàn mới.

Cách chia này phản ánh kịch bản thực tế: mô hình dự báo dịch theo dòng quá khứ - hiện tại – tương lai chuẩn, không xáo trộn để tránh rò rỉ dữ liệu.

Mạng Temporal GAT được khởi tạo với:

- 128 nút ẩn,
- Hai lớp GAT với số head (4,4),
- Dropout 0.2 để giảm quá khớp,
- Khối temporal (GRU–Attention) kích hoạt khi dữ liệu có biến trễ.
- Hàm mất mát sử dụng Huber Loss với ngưỡng $\delta = 1.2$, một lựa chọn trung gian giữa MSE và MAE, nhằm giảm ảnh hưởng cực trị nhưng vẫn giữ độ nhạy với sai số nhỏ. Tối ưu được thực hiện bằng AdamW, với học suất 3e-4 và hệ số phạt trọng số 1e-4.
- Cơ chế dừng sớm và lưu checkpoint: Mỗi epoch, mô hình được huấn luyện trên tập train và kiểm định trên tập val. Nếu mất mát validation không cải thiện trong 30 vòng liên tiếp, huấn luyện sẽ dừng để tránh overfitting. Trọng số tốt nhất được lưu lại dưới dạng checkpoint để dùng cho các bước đánh giá sau.

Hiệu chỉnh ngược (Backtransform) và xử lý ngoại lệ do đầu ra được huấn luyện trong miền log (log1p(y)), cần có bước hiệu chỉnh ngược khi chuyển sang số ca bệnh thực tế. Hai phương pháp được dùng:

- Duan's smearing estimator: hiệu chỉnh sai lệch log–normal.
- Sigma² correction: dự phòng khi smearing không khả dụng.

Khi xuất giá trị dự báo sẽ được chặn theo phân vị 99,9% của tập train để giảm tác động điểm dị biệt.

Hệ thống áp dụng đánh giá kép:

- Không gian log: tính MAE, RMSE, R^2, và Trimmed R^2 để đo lường khả năng khớp.
- Không gian thực: sử dụng MAE, RMSE, SMAPE, R^2 và trimmed R^2 để phản ánh ý nghĩa thực tế.
- Mỗi tuần, các chỉ số được lưu vào bảng tổng hợp (gat_global_weekly_report.csv)
- Một báo cáo tổng hợp (gat_global_summary.json) chứa các chỉ số trung bình (macro) và vi mô (micro) trên từng tập được lưu để so sánh hiệu năng.

2.7. Huyến luyện và đánh giá mô hình Temporal GAT multi-head

Miền log (log1p(cases)) : MAE, RMSE, R^2 và R^2 cắt ngọn (trim 1%) để giảm ảnh hưởng ngoại lệ.

Miền thực (ca/tuần) sau khi nghịch biến đổi + clamp: MAE, RMSE, SMAPE, R^2 và R^2 cắt ngọn.

Tổng hợp:

- Vi mô (micro): gộp tất cả nút-tuần.
- Vĩ mô (macro): trung bình theo từng tuần.
- Cảnh báo bùng phát (từ hồi quy): xem tuần "dương tính" nếu số ca ≥ phân vị 0.90 của thực tế trong từng tập; tính ROC-AUC, PR-AUC, và tỷ lệ dương.

Year	Epiweek	Split	MAE_log	RMSE_log	R2_log	R2trim_log	MAE_real	RMSE_real	SMAPE_real	R2_real	R2trim_real
2021	202101	val	0.158363	0.371094	0.561527	0.660899	0.943793	10.22437	1.840454	0.089305	0.483816
2021	202102	val	0.134042	0.267487	0.791841	0.829753	0.846741	7.885829	1.800187	0.426975	0.731632
2021	202103	val	0.139331	0.281393	0.799425	0.832667	1.019139	10.24275	1.793965	0.319256	0.711335
2021	202104	val	0.143673	0.282104	0.810903	0.841198	1.107973	10.54448	1.78234	0.340913	0.821846
2021	202105	val	0.151753	0.308323	0.805715	0.846642	1.405455	13.0856	1.766689	0.310343	0.768752
2021	202106	val	0.152061	0.305015	0.819759	0.84969	1.625249	16.47981	1.777574	0.286078	0.733605
2021	202107	val	0.166169	0.323219	0.819066	0.848932	1.932659	20.0808	1.754526	0.254959	0.636884
2021	202108	val	0.168159	0.328189	0.818669	0.845553	2.007541	21.16924	1.735274	0.280534	0.721862
2021	202109	val	0.175277	0.346365	0.824954	0.855744	2.330153	26.45896	1.709273	0.208895	0.656021
2021	202110	val	0.181363	0.352932	0.819231	0.851812	2.36801	27.20192	1.708274	0.221238	0.657626
2021	202111	val	0.189008	0.368062	0.819525	0.856492	2.599672	29.81528	1.69515	0.214817	0.609744
2021	202112	val	0.184344	0.358694	0.823301	0.862861	2.574714	31.64279	1.702678	0.202189	0.625947
2021	202113	val	0.191617	0.367168	0.837527	0.869521	3.281788	46.38351	1.69251	0.164127	0.594709
2021	202114	val	0.207995	0.394938	0.832451	0.865774	3.742066	44.89053	1.660045	0.179158	0.597267
2021	202115	val	0.207432	0.385533	0.834722	0.861558	3.399428	37.45124	1.673314	0.22593	0.592567
2021	202116	val	0.203666	0.386603	0.83982	0.86842	3.530758	40.42688	1.664746	0.231173	0.59864
2021	202117	val	0.20863	0.389225	0.833051	0.864451	3.311254	37.42197	1.656627	0.210321	0.592207
2021	202118	val	0.20387	0.372666	0.839193	0.865927	2.886417	31.97902	1.665103	0.302204	0.651935
2021	202119	val	0.201654	0.365864	0.840406	0.864875	2.669627	29.2026	1.653238	0.303663	0.671544
2021	202120	val	0.197888	0.346276	0.840894	0.86604	2.223377	23.79029	1.659235	0.36018	0.689316
2021	202121	val	0.186193	0.337815	0.83133	0.862612	2.017805	23.12708	1.685273	0.323885	0.679737
2021	202122	val	0.179744	0.327759	0.835202	0.860727	1.910078	20.71956	1.685423	0.367093	0.716956
2021	202123	val	0.172431	0.321266	0.834514	0.867798	1.713624	18.73293	1.696613	0.407367	0.722089
2021	202124	val	0.16126	0.29632	0.840675	0.869028	1.41259	14.79792	1.71292	0.440086	0.746576
2021	202125	val	0.149625	0.280944	0.834552	0.867606	1.216461	13.05484	1.748126	0.44577	0.81369
2021	202126	val	0.151382	0.276396	0.825712	0.85835	1.145859	12.01671	1.752642	0.443304	0.762237
2021	202127	val	0.149048	0.26885	0.823252	0.860845	1.050001	11.50525	1.765626	0.365227	0.865831
2021	202128	val	0.141581	0.26424	0.814705	0.850923	0.958776	8.204481	1.784597	0.636007	0.830488
2021	202129	val	0.141114	0.256218	0.806774	0.841088	0.876536	8.476431	1.803064	0.452019	0.766615
2021	202130	val	0.134713	0.246913	0.797568	0.837987	0.732711	5.669736	1.812293	0.630726	0.84593

Bảng 2.2: Gat_global_weekly_report.csv

Tập Val (2021–2022):

- Log (macro): R^2 = 0.794, R^2-trim = 0.831, MAE = 0.185, RMSE = 0.342.
- Thực (macro): R^2 = 0.386, R^2-trim = 0.657, MAE ≈ 2.595 ca, RMSE ≈ 23.02 ca, SMAPE ≈ 1.70%.
- Bùng phát: ROC-AUC = 0.982, PR-AUC = 0.891, pos_rate ≈ 10.8%.

Tập Test (2023–2024):

- Log (macro): R^2 = 0.758, R^2-trim = 0.792, MAE = 0.318, RMSE = 0.544.
- Thực (macro): R^2 = 0.260, R^2-trim = 0.477, MAE ≈ 14.69 ca, RMSE ≈ 163.42 ca, SMAPE ≈ 1.52%.
- Bùng phát: ROC-AUC = 0.975, PR-AUC = 0.784, pos_rate ≈ 10.1%.

Vi mô (gộp):

- Log (micro): R^2 = 0.804, R^2-trim = 0.841, MAE = 0.318, RMSE = 0.597.
- Thực (micro): R^2 = 0.057, R^2-trim = 0.433, MAE ≈ 14.69, RMSE ≈ 278.29, SMAPE ≈ 1.52%.

Checkpoint tốt nhất đạt best_val_loss = 0.0605; thông số nghịch biến đổi:

S=1.128, σ^2_{log} =0.157, cap=528.

```
===== GAT Global Summary =====
best_val_loss              : 0.060466042200389966
smear_train                : 1.1279728412628174
sigma2_train_log           : 0.1574525684118271
cap_train_q999             : 528.0
val_macro_MAE_log          : 0.1851726447238557
val_macro_RMSE_log         : 0.3419300605415883
val_macro_R2_log           : 0.7935149519226636
val_macro_R2trim_log       : 0.8311062480525487
val_macro_MAE_real         : 2.59469369712024
val_macro_RMSE_real        : 23.017795033948005
val_macro_SMAPE_real       : 1.70474072874266
val_macro_R2_real          : 0.3857265249312181
val_macro_R2trim_real      : 0.6572181278144295
micro_MAE_log              : 0.31801881425357664
micro_RMSE_log             : 0.5972463615616879
micro_R2_log               : 0.8043893277365388
micro_R2trim_log           : 0.8413020741812494
micro_MAE_real             : 14.69451755518602
micro_RMSE_real            : 278.28655211902645
micro_SMAPE_real           : 1.5208074133435037
micro_R2_real              : 0.056668323834501266
micro_R2trim_real          : 0.4325993523234384
val_ROC_AUC                : 0.9821703403708255
val_PR_AUC                 : 0.8908776801917032
val_pos_rate               : 0.10807284466073107
test_macro_MAE_log         : 0.31801881425357664
test_macro_RMSE_log        : 0.5438078682234837
test_macro_R2_log          : 0.7584328285181772
test_macro_R2trim_log      : 0.7920941673914283
test_macro_MAE_real        : 14.69451755518602
test_macro_RMSE_real       : 163.41829356448227
test_macro_SMAPE_real      : 1.5208074133435039
test_macro_R2_real         : 0.2602753334679813
test_macro_R2trim_real     : 0.4765918253452424
test_ROC_AUC               : 0.9752484100793205
```

Bảng 2.3: Gat_global_summary.json

Hiệu năng nhất quán ở miền không gian log: R^2-trim cao trên cả val và test cho thấy mô hình học tốt quan hệ khí hậu-mật độ-lan truyền trên phần lớn phân bố, trong khi vẫn xử lý được ngoại lệ nhờ HuberLoss và R^2-trim.

Quy đổi về ca thực chịu tác động đỉnh dịch: Trên val, sai số thực ở mức thấp; sang 2024, RMSE thực tăng và R^2 giảm do dịch chuyển phân phối (xuất hiện đỉnh lớn hơn miền huấn luyện). Tổ hợp smearing + clamp giúp ổn định nhưng không loại bỏ hoàn toàn sai số khi có siêu bùng phát.

Khả năng cảnh báo hữu ích: Dù RMSE thực tăng ở 2024, ROC-AUC/PR-AUC vẫn cao (>0.97 và >0.78), nghĩa là điểm dự báo dùng tốt để xếp hạng tuần/ngã ba nguy cơ cho mục tiêu phân bổ nguồn lực kiểm soát muỗi truyền.

Năng lực giải thích cao ở miền log và khả năng phân loại bùng phát rất tốt, phù hợp dùng làm cảnh báo sớm.

Khi quy đổi về ca thực, mô hình ổn định giai đoạn 2021–2023, nhưng giảm trên 2024 do thay đổi phân phối — một hướng mở làm phát triển cho các chiến lược cập nhật theo mùa và mở rộng đặc trưng. Có thể xem lại quá trình huấn luyện tại phụ lục hình 3.6

Chương 3. TRỰC QUAN HÓA DƯỚI DẠNG BẢN ĐỒ THỂ HIỆN SỰ LAN TRUYỀN BỆNH SỐT XUẤT HUYẾT Ở CÁC KHU VỰC CÙNG YẾU TỐ THỜI GIAN

3.1. Mục tiêu trực quan hóa

Giai đoạn trực quan hóa là chuyển đổi cá kết quả định lượng từ mô hình Spatial - Temporal Graph Attention Networks để biểu diễn trực quan và cảm quan dễ dàng cho những nhà nghiên cứu, bác sĩ dịch tễ và các cán bộ y tế có thể dễ dàng nhìn nắm bắt xu hướng lây lan bệnh sốt xuất huyết. Thông qua bản đồ, bảng điều khiển có thể tương tác:

- Quan sát sự biến động ca bệnh theo thời gian (tuần, năm).
- So sánh mức độ dự báo và số liệu thực tế theo từng địa phương.
- Phát hiện sớm các vùng có nguy cơ bùng phát dịch.
- Hỗ trợ ra quyết định phòng chống dịch dựa trên dữ liệu trực quan thay vì chỉ các bảng số liệu khô khan.
- Bản đồ choropleth theo tuần để thấy không–thời gian dịch chuyển của nguy cơ
- Lớp "lưới liên kết" (graph) thể hiện kết nối giữa các đơn vị để hỗ trợ diễn giải lan truyền theo không gian.
- Bảng/tổng hợp nhanh theo tuần và theo địa phương phục vụ giám sát xu hướng, so sánh "dự báo – thực tế", và tìm điểm nóng. Toàn bộ trực quan hóa được thiết kế theo hướng "offline-first": dữ liệu trung gian được chuẩn hóa thành Parquet/JSONL, vì vậy có thể nạp vào bất kỳ công cụ BI hay web map nào mà không phụ thuộc môi trường chạy.

3.2. Nền tảng công cụ

3.2.1. convert_node_predictions.py — Bước 1

Trong quá trình triển khai hệ thống trực quan hoá, một yêu cầu quan trọng là chuẩn hoá và tối ưu hoá dữ liệu đầu ra từ giai đoạn huấn luyện mô hình. Tệp mã convert_node_predictions.py đảm nhiệm vai trò này bằng cách chuyển đổi các tập tin kết quả (CSV, JSON) sang định dạng Parquet và JSONL, đồng thời tổ chức dữ liệu theo phân vùng tuần–năm (Hive partitioning). Mục tiêu là đảm bảo dữ liệu có cấu trúc rõ ràng, dễ truy vấn theo chiều thời gian, và tương thích với nền tảng xử lý dữ liệu hiện đại như PyArrow và Pandas.

Nguồn dữ liệu đầu vào bao gồm ba nhóm:

- gat_global_weekly_report.csv: thống kê hiệu năng theo từng tuần.
- gat_global_summary.json: tóm tắt toàn bộ quá trình huấn luyện và đánh giá.
- node_predictions.csv: kết quả dự báo chi tiết ở cấp độ từng nút–tuần (có kích thước rất lớn).

Kết quả chuyển đổi được lưu dưới dạng:

- weekly_report.parquet cho báo cáo tuần,
- Summary.jsonl và summary.parquet cho dữ liệu tổng hợp,
- thư mục dữ liệu phân vùng Hive node_predictions_ds/Year=YYYY/Epiweek=WW/… chứa các tệp Parquet shard nhỏ, thuận lợi cho tải song song hoặc truy vấn chọn lọc.
- Chuẩn hoá dữ liệu tuần–năm: ép kiểu Year và Epiweek sang số nguyên 64-bit, chuyển các cột phân loại (Split) sang kiểu chuỗi, đảm bảo nhất quán trong toàn bộ pipeline.
- Chuyển đổi và nén dữ liệu: các bảng nhỏ như báo cáo tuần và tóm tắt được chuyển thành Parquet với nén Zstandard (zstd) và row group kích thước 128 nghìn bản ghi, giúp cân bằng giữa tốc độ đọc/ghi và dung lượng lưu trữ.
- Xử lý dữ liệu lớn node-level: đọc tệp node_predictions.csv theo khối 200 nghìn dòng để tránh tràn bộ nhớ trên cấu hình phổ thông (CPU i7, RAM 16 GB). Sau đó dữ liệu được cưỡng bức kiểu theo schema định nghĩa trước, phân vùng Hive theo năm–tuần và chia shard với giới hạn 2 triệu dòng/tệp.

Các cơ chế đảm bảo hiệu năng và chất lượng:

- Phân vùng Hive cho phép chỉ tải dữ liệu cần thiết theo năm/tuần khi trực quan, thay vì nạp toàn bộ.
- Row group và nén zstd hỗ trợ kỹ thuật predicate pushdown và column pruning, giúp tăng tốc độ lọc và chọn cột khi hiển thị dashboard.
- Sharding dữ liệu giảm rủi ro ghi đè tên file và giữ cho mỗi tệp có kích thước vừa phải.
- Kiểm soát chất lượng được thực hiện thông qua kiểm tra sự tồn tại của cột phân vùng (Year, Epiweek) và ép kiểu dữ liệu nghiêm ngặt. Nếu thiếu cột hoặc dữ liệu không hợp lệ, hệ thống sẽ thông báo lỗi thay vì tiếp tục xử lý.

3.2.2. Kiểm tra inspect_node_predictions_schema.py — Bước 2

Sau khi chuyển đổi và phân vùng kết quả dự báo nút–tuần sang Parquet Dataset (mục 3.2.1), bước tiếp theo là kiểm chứng cấu trúc bộ dữ liệu để đảm bảo tính tương thích với các mô-đun trực quan hoá. Mã inspect_node_predictions_schema.py thực hiện "khám sức khoẻ" nhanh cho dataset phân vùng Hive bằng cách: (i) đọc lược đồ (schema) do PyArrow suy diễn, (ii) trích xuất một mẫu nhỏ để quan sát, (iii) liệt kê các tên cột ở dạng chuẩn hoá, và (iv) gợi ý cột mã địa phương/đơn vị hành chính (geocode) nhằm phục vụ bước ghép toạ độ/bản đồ.

Dữ liệu đầu vào/đầu ra

- Đầu vào: thư mục visualizations/parquet/node_predictions_ds/ là Parquet Dataset đã được phân vùng theo cấu trúc Hive Year=YYYY/Epiweek=WW/….

Đầu ra màn hình:

- Schema đầy đủ (kiểu dữ liệu, tên cột) theo PyArrow.
- Mẫu 10 dòng đầu tiên (để kiểm tra nhanh nội dung, giá trị thiếu, kiểu dữ liệu thực tế).
- Danh sách tên cột đã chuyển về chữ thường (hỗ trợ dò tìm đồng nhất).
- Gợi ý cột geocode: trả về các biến có khả năng là mã đơn vị hành chính (ví dụ: region_code, geocode, code_muni, …). Nếu không khớp tên nào, chương trình nhắc người dùng kiểm tra trực tiếp 10 dòng mẫu để nhận diện trường phù hợp.

Quy trình thực thi:

- Khởi tạo dataset: dùng pyarrow.dataset.dataset(..., format="parquet", partitioning="hive") đọc toàn bộ tập dữ liệu theo chuẩn Hive, giúp PyArrow hiểu đúng cặp khóa phân vùng Year/Epiweek.
- In lược đồ: xuất dataset.schema để xác nhận kiểu mỗi trường (số, chuỗi, dấu phẩy động) và phát hiện sớm sai lệch do ép kiểu ở bước chuyển đổi.
- Lấy mẫu: dataset.take(range(10)) trích 10 bản ghi đầu tiên, chuyển sang Pandas cho phép "soi" giá trị thực tế, phát hiện nhanh cột bị rỗng hoặc lệch định dạng.
- Chuẩn hoá tên cột: chuyển toàn bộ tên về chữ thường, giảm nhầm lẫn khi gọi cột ở các bước kế tiếp (đặc biệt quan trọng khi tích hợp nhiều nguồn).
- Heuristic nhận diện geocode: so khớp tên cột với một danh sách ứng viên (ví dụ region_code, geocode, municipio_id, cd_geocmu…), từ đó đề xuất trường đại diện mã lãnh thổ. Đây là tiền đề để ghép với centroid/tọa độ hoặc shape phục vụ bản đồ bệnh sốt xuất huyết.

Vai trò trong pipeline trực quan hoá:

- Giảm rủi ro lỗi về schema: nếu có khác biệt giữa schema mong đợi (ví dụ: Year/Epiweek không phải int64 hoặc Split không phải chuỗi) sẽ phát hiện ngay tại đây, trước khi xây dựng dashboard.
- Bảo đảm trường ghép không gian: việc gợi ý cột geocode giúp chuẩn bị cho các bước rebuild_centroids, validate_and_fix_edges và các bản đồ choropleth/time-lapse.
- Tiết kiệm chi phí thao tác: xem nhanh 10 dòng đại diện giúp đánh giá "mùi" dữ liệu (missing, outlier định dạng) mà không phải nạp toàn bộ dataset lớn.

3.2.3. Chuẩn bị dự liệu Prepare_visual_data.py – Bước 3

Sau khi đã kiểm tra lược đồ thì, bước này sẽ dựng các gói dự liệu phục vụ dashboard ngoại tuyến đáp ứng gọn nhẹ, đọc theo tuần, và tương thích PyArrow ≥21. Trọng tâm là chuẩn hóa tên/kiểu cột, chia partition theo year/epiweek, tính toán chỉ số tổng hợp theo

thời gian, và sẵn sàng các lớp không gian (biên giới, centroid, cạnh) cho nhiều chế độ hiển thị (choropleth, điểm, mật độ, mạng).

Quy trình thực hiện:

Bước 1 — Xây panel_node_ds tối giản:

- Nạp node_predictions_ds/ bằng PyArrow Dataset với partition Hive; chỉ chọn các cột cần: Split/split, geocode/region_code/NodeID, Year/year, Epiweek/epiweek, y_true(_real), y_pred(_real).
- Chuẩn hóa lược đồ: Đặt tên cột chuẩn: split, geocode (int64), year (int32), epiweek (int32), y_true (float32), y_pred (float32).
- Chặn âm cho y_pred (max với 0).
- Tự tính residual = y_true - y_pred nếu đủ cột.
- Thiếu split → gán "unknown".
- Ghi lại theo partition year/epiweek với nén Zstd, kích thước row group cố định để tối ưu IO (thân thiện RAM 16 GB).

Bước 2 — Tổng hợp theo tuần:

- Từ panel_node_ds/, gom nhóm theo (year, epiweek) và tạo các chỉ số: n, mean_pred, sum_pred, mean_true, sum_true.
- Ghi panel_node_agg.parquet để sử dụng cho thống kê dòng thời gian (thanh trạng thái của dashboard).

Bước 3 — Tạo choropleth JSONL mỗi tuần:

- Nạp geocode, year, epiweek, y_pred, y_true từ panel_node_ds/.
- Gom theo tuần và ghi mỗi tuần một file JSONL geocode, y_pred, y_true.
- Mục tiêu: cho phép render ngoại tuyến, tải nhanh theo frame thời gian mà không cần đọc lại toàn bộ dataset lớn.

Bước 4 — Xử lý edges (mạng lưới cạnh):

- Ưu tiên edge_list.csv: tự nhận diện cột (ví dụ: src/dst, u/v, from/to) và chuẩn hóa về src, dst (int64).
- Nếu không có CSV, thử edge_index.pt (PyTorch Tensor [2, E]).
- Làm sạch: bỏ self-loop, loại trùng, ép kiểu chắc chắn → ghi edges.parquet.
- Mục đích: giảm đồ họa rối, đảm bảo tính hợp lệ khi vẽ layer cạnh.

Bước 5 — Biên giới & centroids:

- Sao chép GeoJSON nguồn sang visualizations/geo/ để JSON có sẵn khi chạy offline.
- Nếu có geopandas: tính centroid đa giác và lưu muni_centroids.parquet với geocode, lon, lat.
- Hệ toạ độ mặc định WGS84; mô-đun xử lý trường hợp thiếu crs và map cột khoá id/geocode.

Bước 6 — Meta theo geocode:

- Duyệt luồng dữ liệu từ panel_node_ds/ để lập bảng tĩnh:
- pred_min, pred_max, pred_mean, weeks trên từng geocode.
- Kết quả geocode_meta.parquet hỗ trợ: đặt kích thước điểm theo quy mô, lọc các điểm hiếm gặp, và tham số hóa hover.

Lựa chọn kỹ thuật & tối ưu hiệu năng

- PyArrow 21+: dùng dataset.scanner + write_dataset với partitioning(schema, flavor="hive"); tránh API cũ (WriterProperties/append).
- Kiểm soát bộ nhớ: batch size và row group cố định (BATCH_SIZE≈256k, ROW_GROUP≈128k) giúp cân đối tốc độ/nhớ.
- Ép kiểu an toàn: mọi trường số đều to_numeric/compute.cast, loại NaN trên cột khoá; không giả định định dạng hoàn hảo.
- Tách nhỏ sản phẩm: panel gọn + JSONL theo tuần → dashboard chỉ tải đúng phần cần.

Kiểm tra & đảm bảo chất lượng:

- Dừng sớm nếu thiếu cột bắt buộc (geocode, year, epiweek) hoặc không tìm thấy dữ liệu.
- Cạnh: báo cảnh báo khi không có tệp nguồn; khi có, bỏ self-loop, trùng lặp trước khi ghi.
- GeoJSON: xác minh có id/geocode; nếu không, thông báo rõ ràng để người dùng bổ sung.
- Ngưỡng dữ liệu đầu ra: thống kê số dòng, số tuần, số geocode sinh meta để đối chiếu nhanh.

3.2.4. Xây dựng tâm đa giác rebuild_centroids.py – Bước 4

Trong hệ thống trực quan hoá dịch tễ, mỗi đơn vị hành chính (huyện/xã) cần được gắn tọa độ trung tâm (centroid) để có thể hiển thị chính xác trên bản đồ. Script rebuild_centroids.py đảm nhận việc này dựa trên file biên dạng hành chính quốc gia (geojs-100-mun.json hoặc geojs-100-mun.geojson).

Quy trình thực hiện:

- Xác định cột khoá: chương trình dò tìm các trường geocode hoặc id trong GeoJSON để làm định danh duy nhất cho từng vùng.
- Chuẩn hoá hệ quy chiếu: nếu dữ liệu không có CRS, hệ toạ độ mặc định EPSG:4326 (WGS84) được gán. Sau đó dữ liệu được chuyển sang hệ quy chiếu phẳng EPSG:5880 (Brazil Polyconic) để tính tâm hình học chính xác hơn.
- Tính centroid: trung tâm đa giác được tính trong CRS phẳng, sau đó chuyển ngược về EPSG:4326 để thu được kinh độ–vĩ độ.

- Xuất kết quả: tập tin muni_centroids.parquet chứa geocode, lon, lat và tên đơn vị (nếu có), đồng thời bản sao của file gốc GeoJSON được lưu lại trong thư mục visualizations/geo/.

3.2.5. Kiểm tra và làm sạch cạnh validate_and_fix_edges.py – Bước 5

Bên cạnh dữ liệu vị trí, cấu trúc mạng lưới kết nối không gian (cạnh) cũng phải được chuẩn hoá để mô hình GNN và dashboard hoạt động đúng. Script validate_and_fix_edges.py, xử lý danh sách cạnh thô (edge_list.csv) và bảo đảm chúng phù hợp với tập geocode đã xây dựng ở bước trước.

Các bước chính:

- Đọc cạnh đầu vào: hỗ trợ nhiều định dạng cột (a,b, src,dst, u,v, …) và tự động chuẩn hoá về hai cột a,b.
- Nhận diện chế độ: dựa trên giá trị min/max, chương trình phân biệt cạnh lưu ở dạng chỉ số (index) hay mã địa phương (geocode).
- Ánh xạ index → geocode: nếu là dạng chỉ số, các giá trị được ánh xạ về geocode hợp lệ dựa trên thứ tự tăng dần.
- Làm sạch cạnh: loại bỏ self-loop, cạnh trùng lặp, cạnh chứa geocode ngoài tập hợp centroid hợp lệ.
- Thống kê nhanh: báo cáo phân bố bậc (degree) của các nút để phát hiện bất thường.
- Xuất kết quả: lưu tập cạnh đã làm sạch dưới dạng edges.parquet trong thư mục visualizations/prepared/.
- Đảm bảo tính nhất quán, giảm nhiễm dữ liệu và tối ưu cho dashboard.

3.3. Bảng điều khiển kết quả dashboard - export_dashboard.py

Mục tiêu của mô-đun là xuất một tệp HTML tự chạy, hoàn toàn ngoại tuyến để khai thác dự báo/quan sát sốt xuất huyết theo không–thời gian. Dashboard phải phát lại theo tuần mượt, cho phép bật/tắt lớp dữ liệu không gian, cố định thang màu theo toàn bộ giai đoạn để so sánh nhất quán, và vận hành ổn định trên máy tính phổ thông, không cần máy chủ hay notebook.

3.3.1. Dòng dữ liệu đầu vào:

- Bảng panel theo tuần: Parquet dạng hive partition year=yyyy/epiweek=yyyyww (thư mục visualizations/prepared/panel_node_ds). Mỗi tuần chứa geocode, y_true, y_pred, residual, year, epiweek, split.
- Trung tâm đa giác: visualizations/geo/muni_centroids.parquet (tọa độ lon/lat cho từng geocode).
- Danh sách cạnh đã làm sạch: visualizations/prepared/edges.parquet (các cặp src–dst hợp lệ, đã loại self-loop và trùng lặp).
- Siêu dữ liệu sinh thái (nếu có): data/raw/environ_vars.csv (biome, Köppen, tên đơn vị) để làm giàu nội dung hover.
- GeoJSON biên giới: visualizations/geo/geojs-100-mun.json cho lớp nền hành chính.
- Sử dụng PyArrow Dataset để lọc theo partition tuần.
- Pandas cho xử lý cục bộ; các cột khóa được ép kiểu an toàn geocode → int64
- Bảo đảm không vỡ định dạng khi vẽ.

3.3.2. Kiến trúc hiển thị và tương tác

a. **Truy vết lớp (layer order và vai trò)**

Dashboard tổ chức 7 lớp, được sắp xếp nhằm giữ ngữ nghĩa thị giác rõ ràng:

Biome (tắt mặc định): tô nền sinh cảnh (mờ, RGBA) để cung cấp ngữ cảnh môi trường mà không che phủ dữ liệu chính.

Truth: choropleth số ca thực tế, dùng thang màu liên tục (mặc định Turbo; có thể đổi Viridis, Inferno…) và zmax cố định theo toàn kỳ.

Prediction: choropleth dự báo, cùng họ thang màu với Truth để thuận so sánh.

Residual: choropleth sai số, dùng thang phân kỳ (mặc định RdBu) với tâm 0; trục màu đối xứng theo |residual| lớn nhất toàn kỳ.

Density (tắt mặc định): heatmap mật độ điểm để nhận diện hội tụ ca bệnh.

Centroids (tắt mặc định): điểm trung tâm đơn vị hành chính, kích thước tỉ lệ cường độ ca bệnh tuần đó.

Edges (tắt mặc định): mạng lưới kết nối giữa đơn vị (đường mảnh, trong suốt) dùng để gợi ý luồng lan truyền.

Việc duy trì thứ tự này giúp lớp nền (Biome) không che dữ liệu, trong khi cạnh/điểm xuất hiện nổi ở trên cùng khi bật.

b. Thang màu và chuẩn hóa phạm vi

Truth/Prediction: zmin = 0, zmax là giá trị lớn nhất toàn bộ tập tuần đã chọn → màu sắc cùng một ý nghĩa xuyên suốt, tránh "nhảy" thang khi tua.

Residual: zmid = 0, zmin = -M, zmax = +M với M = max |residual| toàn kỳ → dương/âm thể hiện quá/thiếu dự báo cân xứng.

Density: dùng coloraxis2, tách biệt với thang của choropleth để không xung đột.

c. Phát lại theo thời gian (animation ngoại tuyến)

Thay vì slider tích hợp của Plotly, script dùng requestAnimationFrame + Plotly.restyle:

Play/Pause/Restart: ba hành động độc lập, tránh tồn đọng sự kiện.

Tốc độ "N tuần / S giây": điều chỉnh hạt thời gian mượt, thân thiện.

Timeline kéo thả: thanh trượt tuần (YYYY–Www) cho phép nhảy tức thì; mọi thao tác kéo đều tạm dừng phát.

Tối ưu colorbar: dashboard đếm số lớp choropleth đang bật, tự bố trí colorbar lệch phải theo 1–3 cột, đồng thời điều chỉnh margin.r để không bị chồng lấn (ví dụ: 1 colorbar ~120px; 3 colorbar ~280px).

d. Gói dữ liệu tuần cho JS (datapack)

Mỗi tuần được đóng gói tối giản cho client:

locs: danh sách geocode (string) để ánh xạ vào featureidkey của mapbox.

z_true, z_pred, z_res: mảng số liệu đã coerce và điền NaN an toàn.

hov_*: chuỗi hover đã ghép thông tin sinh thái (tên, biome, Köppen).

Thống kê cảm quan: tổng ca, trung bình dự báo, RMSE tuần, Top-5 địa phương. Các số liệu này cập nhật trực tiếp ở thanh trạng thái khi tua.

3.3.3. Giao diện người dùng

- Bảng điều khiển kéo–thả (draggable) chứa bộ bật/tắt lớp, đổi bảng màu, giúp cấu hình nhanh.
- Thanh điều khiển dưới: nút Play/Pause, Restart; lựa chọn tốc độ; timeline; và một khối thống kê (Tuần, RMSE, Tổng ca, Mean dự báo, Top-5) cập nhật theo frame.
- Hover chi tiết: hiển thị geocode, giá trị tại lớp đang xem, tên địa phương (nếu có), biome và Köppen.

3.3.4. Khía cạnh hiệu năng

- Đọc tuần theo partition: chỉ nạp đúng year, epiweek cần, giảm IO.
- Giới hạn hiển thị: tham số --max-nodes chọn N nút lớn nhất theo y_true trong tuần để bảo toàn tốc độ; --max-edges cắt ngưỡng số cạnh.
- Restyle thay vì redraw: cập nhật dữ liệu cho trace hiện có (không tạo trace mới), tránh giật hình.
- HTML tự chứa: toàn bộ JS/CSS/Plotly được nhúng, chạy ngoại tuyến, giảm phụ thuộc mạng.

3.3.5. Tham số chạy và đầu ra

- Tham số chính: --max-edges (mặc định 12 000), --max-nodes (3 000), --start-week/--end-week (lọc cửa sổ thời gian, định dạng YYYY_WW), --no-hover (tắt hover để nhẹ hơn), --out (đường dẫn HTML).
- Kết quả: một tệp visualizations/dashboard_chinhthuc.html có thể mở trực tiếp bằng trình duyệt để trình bày hoặc chụp ảnh minh họa.

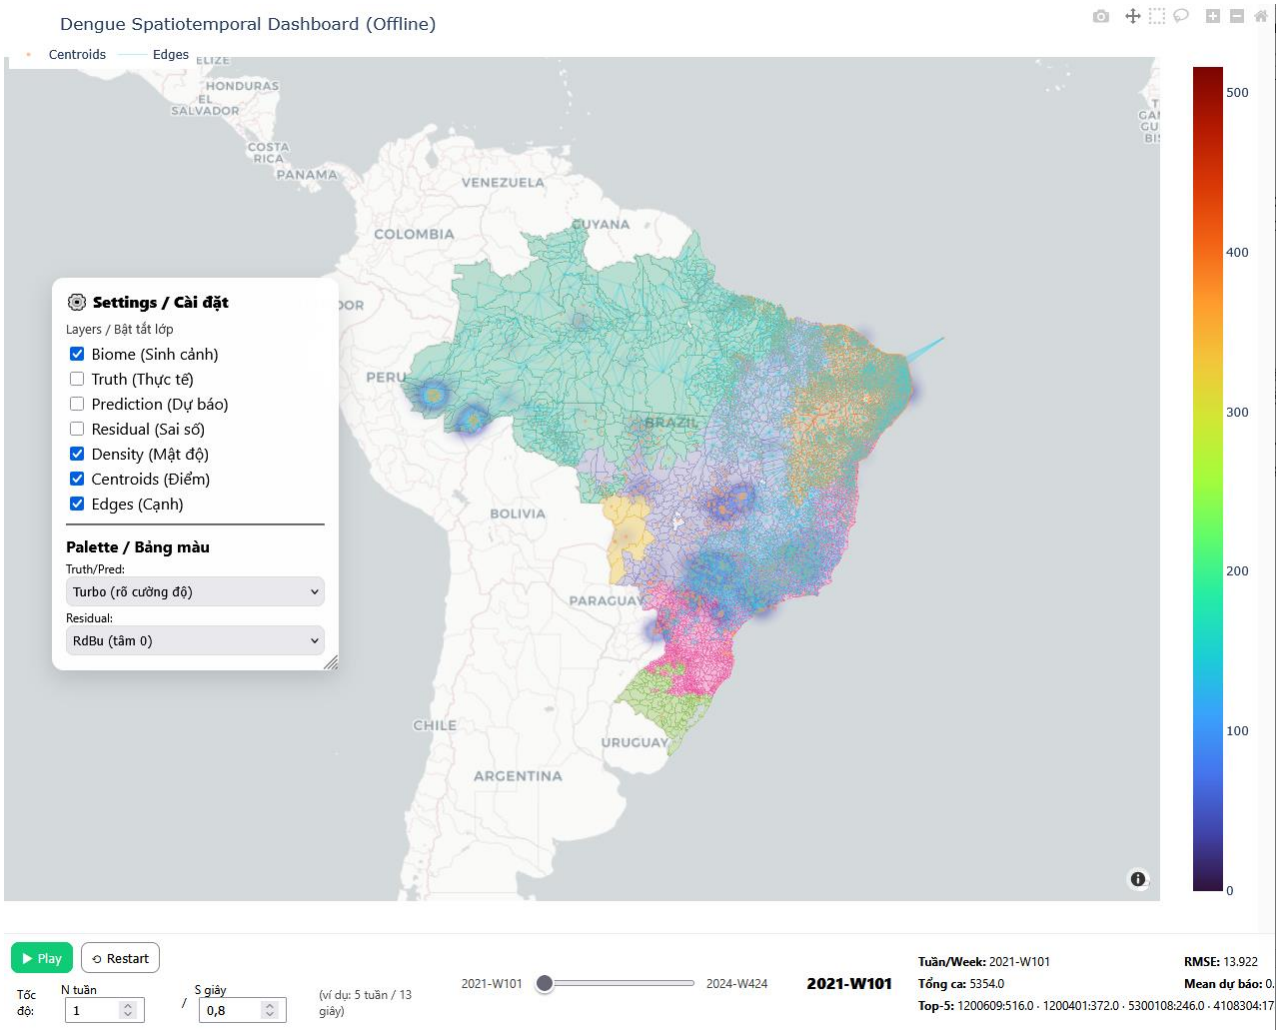
3.3.6. Kiểm soát chất lượng hiển thị

- Nhất quán thang màu theo toàn kỳ: đảm bảo diễn giải trực quan đúng nghĩa so sánh giữa các tuần.
- Bố trí colorbar động theo số lớp bật: tránh chồng chéo và mất chữ.
- Xử lý thiếu dữ liệu: ép kiểu, loại hàng thiếu geocode, và ràng buộc kiểu số nhằm phòng ngừa lỗi render.
- Tách biệt palette Residual: buộc tâm 0 (diverging), giúp nhận biết sai số âm/dương rõ rệt.

3.3.7. Hạn chế & hướng mở rộng

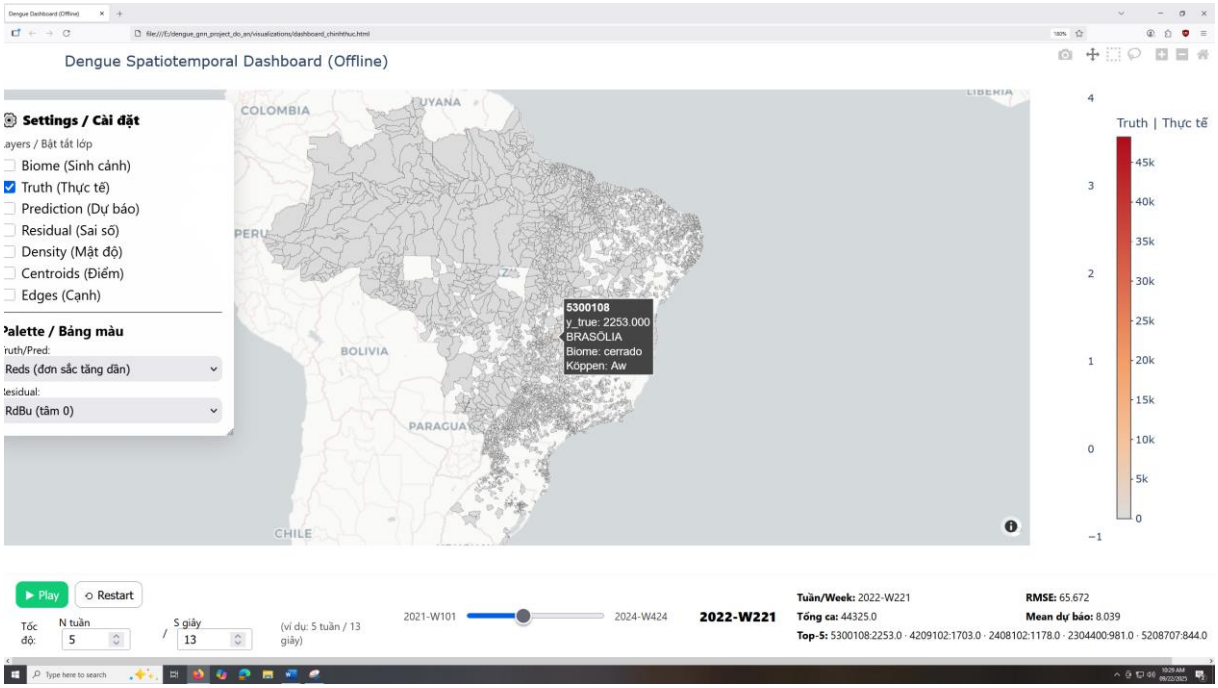
- Mức chi tiết cao (nhiều đa giác) sẽ làm choropleth nặng; có thể áp dụng tổng hợp theo cấp tỉnh hoặc cơ chế tile hóa để tăng FPS.
- RMSE tuần hiện tính trực tiếp từ z_true, z_pred đã nạp; có thể mở rộng thêm MAE, SMAPE và biểu đồ phụ (sparkline) ở thanh trạng thái.
- Truy vấn vùng: tương lai có thể bổ sung click vào đa giác để mở mini-panel lịch sử thời gian cho địa phương đó.

3.4. Đánh giá và phân tích trực quan & cảm quan



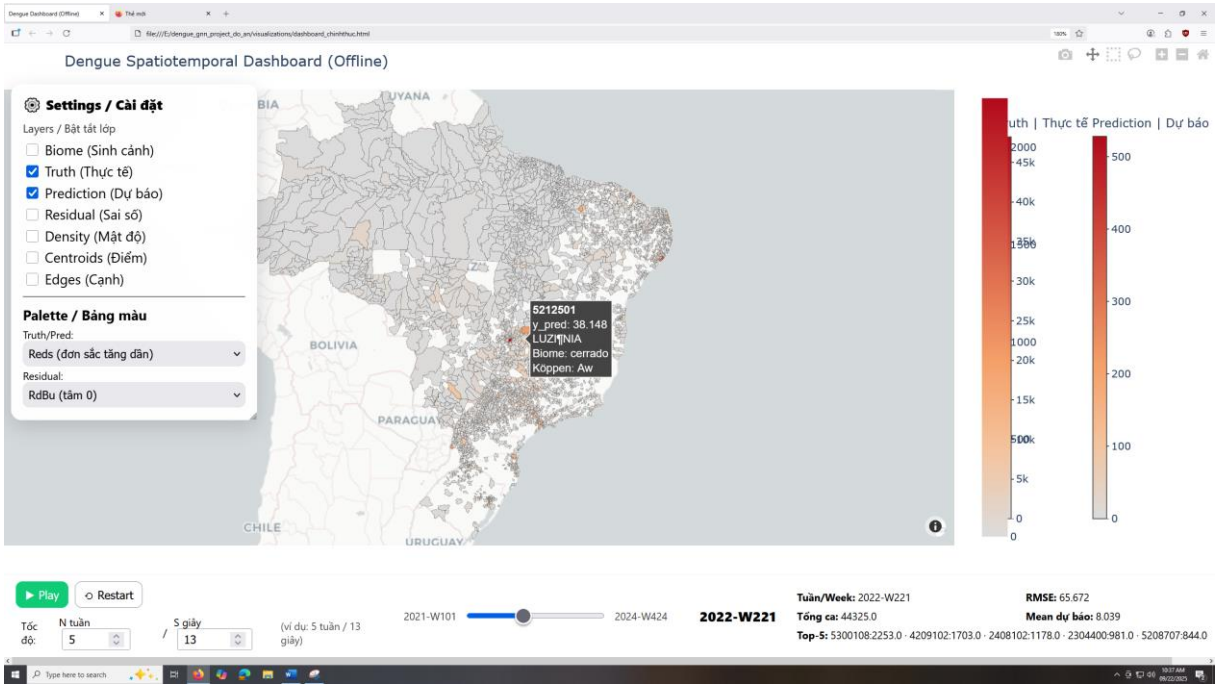
Bảng 3.1: Dashboard_chinhthuc.html

Thông qua đó ta có thể nhìn rõ độ đậm nét và nhét nét từng lớp cài đặt, thể hiện rõ sự trực quan hóa và cảm quan hóa dành cho cán bộ nhân viên y tế lẫn nhưng chuyên gia trong lĩnh vực nói chung và riêng. Bảng điều khiển có đầy đủ các tham số bên góc trái có thể xác định top 5 những địa phương có số ca lớn bùng phát. Nhưng chỉ số bổ trợ cho việc ra dự đoán cũng như có thể chỉnh bảng màu cho nhiều cài đặt khác nhau. Bao gồm bảng màu: Rõ cường độ, nhấn điểm nóng, đơn sắc đỏ tăng dần, xanh đơn sắc tăng dần, và thậm chí có cả chế độ mù màu thân thiện cho những người không có khả năng cảm nhận màu sắc. Dòng thời gian chạy trên một trục và một chiều thể hiện rõ mạch thời gian. Các thanh chỉ số thể hiện mực độ chỉ số dựa trên layer tùy chọn và hiển thị có khả năng thay đổi chi tiết. Các lớp có thể bật tắt bao gồm sinh cảnh, số ca thực tế - dự đoán, sai số, mật độ, điểm, cạnh.



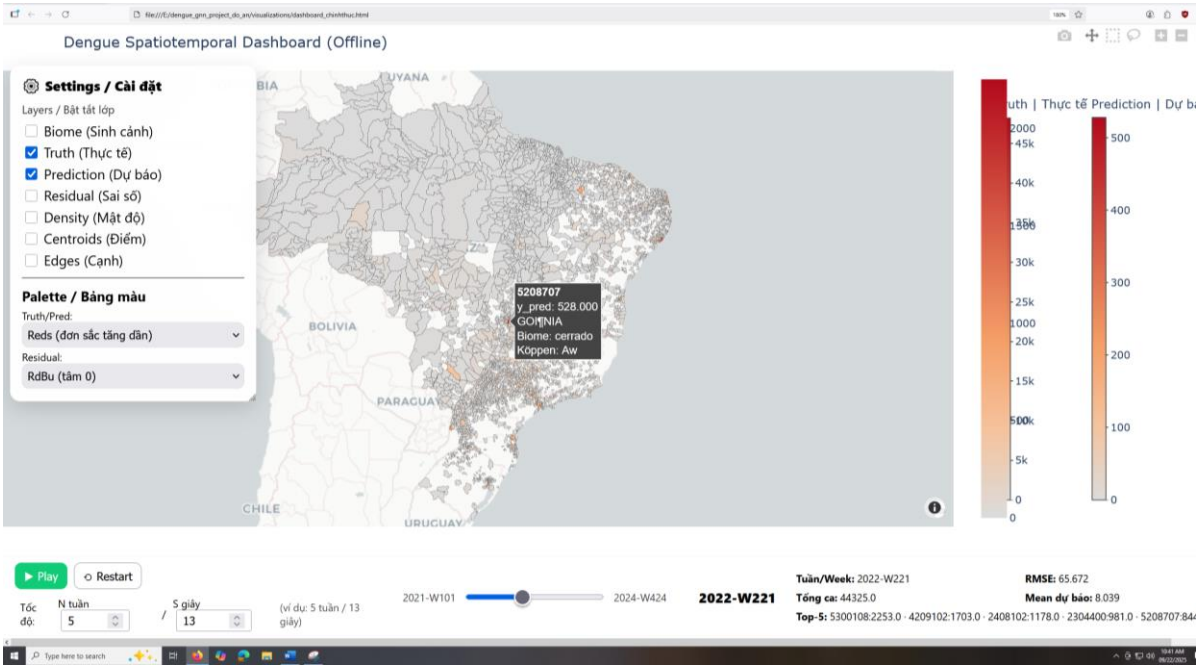
Bảng 3.2: Dashboard trình chiếu layer Truth (Thực tế)

Trong cắt nhỏ tuần 21 tại năm 2021 ta có thể nhìn thấy địa phương Brasolia có mã geocode 5300108 có số ca bộc phát thực tế là 22530 ca sốt xuất huyết cao nhất trong top 5 trong bảng màu đỏ đơn sắc tăng dần, thể hiện sự phân rõ cụn và ảnh hưởng.



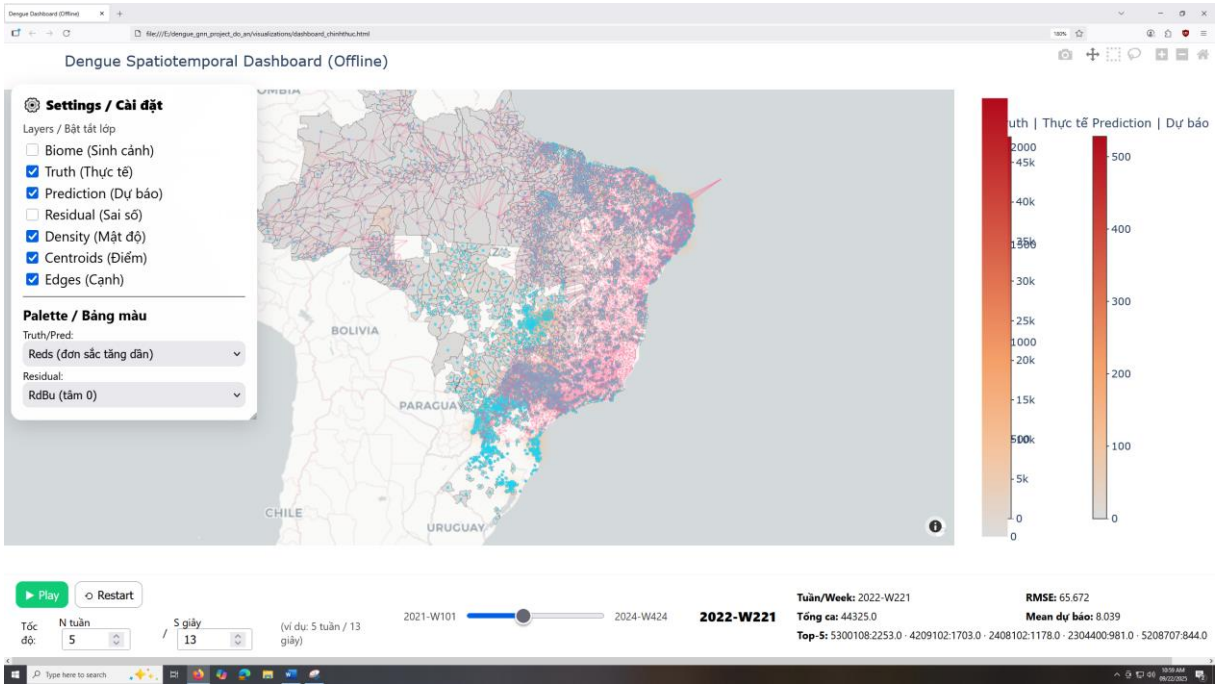
Bảng 3.3 Dashboard trình chiếu layer Truth (Thực tế) – Prediction (Dự báo)

Việc địa phương Brasolia Có ca bệnh sốt xuất huyết tăng mạnh đều dẫn đến sự lây lan mạnh các cùng lân cận cũng như thể hiện sự tương quan giữa các vùng nhu kề Luziinia có mã geocode 5212501 có khả năng bùng phát cao 38 người khởi phát.



Bảng 3.4 Dashboard trình chiếu địa phương 5208707

Địa phương 5208707 có thể hiện sự tăng mạnh khả năng bị sốt xuất huyết với khởi phát 528 người cùng mean dự báo 8 và RSME 65 đều đó có ý nghĩa cho thấy mô hình vẫn nhận diện được tín hiệu dịch tễ. Tuy nhiên, giá trị trung bình dự báo chỉ khoảng 8 ca tức là các ca bệnh trải đều địa phương rải rác và thấp, RMSE = 65 cho thấy sự chênh lệch đáng kể giữa dự báo và thực tế nghĩa là ở những giai đoạn cao điểm có thể bỏ lỡ thấp hơn so với ca bệnh thực sự. Ý nghĩa thực tiễn có thể nắm bắt liên tục xu hướng dịch và dự báo chính xác nhưng chưa gom đủ ổn định số ca tổng.



Bảng 3.5: Dashboard bật đa lớp layer phủ

Khi bật đa lớp phủ thì thông qua số nút và điểm tại địa phương xung quanh 5208707 đều cho thấy sự cao về mật độ dân số, điểm và cạnh liên kết trực tiếp và phức tạp thể hiện rõ sự tương quan cho rằng mô hình nắm bắt hợp lý về số ca bệnh sốt xuất huyết và xu hướng về bổ trợ thêm lớp phủ Mật độ, điểm nút và cạnh. Bởi lý luận vậy càng chứng minh rằng mô hình Spatial-Temporal Graph Attention Network có thể học tất cả chỉ số đa nền tảng dữ liệu, từ không gian đến thời gian một trục hợp lý đa góc nhìn, từ từ số ca dịch tễ sốt xuất huyết đến khí hậu, dân số, sự tương quan và liên kết vùng và cấp vùng, và thể hiện rõ quần xã sinh học thông qua đó đều có thể đáp ứng các nhu cầu cần thiết cho xã hội như huấn luyện một mô hình có thể dự đoán tốt nắm bắt các xu hướng về vùng có ca sốt xuất huyết khả năng cao bùng phát để có thể cán bộ y tế đưa ra các biện pháp xử lý kịp thời, tránh mọi thứ diễn ra ngoài tầm kiểm soát. Không những dự đoán mà còn có thể trực quan và cảm quan dễ dàng dành cho đa người dùng có thể quan sát từ nhiều bảng màu và lớp phủ layer, mọi người có thể quát sát đưa ra nhiều dự định lập luận nhưng đều cùng về một hướng dự đoán chính xác vùng bùng dịch và phân cụm rõ ràng. Quan sát không chỉ dừng tại một thời điểm mà có thể xem xét rõ nét từng thời điểm với đa bộ chỉ số kèm theo. Mạng lưới networks thể hiện rõ sự liên kết mạch địa phương qua lại với nhau, sự tương quan và ảnh hưởng cũng như điều tiết các dân số qua lại tạo nên góc nhìn về sự lan truyền bệnh sốt xuất huyết trong thời đại mới.

TÀI LIỆU THAM KHẢO

(Theo chuẩn IEEE)

[1] Mosqlimate Project, "Mosquito, Climate and Dengue Data Platform," 2024. [Online]. Available: https://mosqlimate.org. [Accessed 16 September 2025].

[2] N. M. S. Sansone, M. N. Boschiero and F. A. L. Marson, "Dengue outbreaks in Brazil and Latin America: the new and continuing challenges," *International Journal of Infectious Diseases,* vol. 147, p. 107192, 2024.

[3] Instituto Brasileiro de Geografia e Estatística (IBGE), "Malhas Municipais: Municípios do Brasil," 2018. [Online]. Available: https://www.ibge.gov.br/geociencias/downloads-geociencias.html. [Accessed 21 September 2025].

[4] Pan American Health Organization (PAHO), Dengue: Guidelines for diagnosis, treatment, prevention and control, 2nd ed ed., Washington DC: Pan American Health Organization, 2019.

[5] F. J. Colon-Gonzalez, I. R. Lake and G. Bentham, "Climate variability and the epidemiology of dengue," *Int. J. Environ. Res. Public Health,* vol. 8, no. 6, p. 2231–2249, 2011.

[6] T. Dostal, J. Meisner, C. Munayco, P. J. García, C. Cárcamo and L. E. P. Lu, "The effect of weather and climate on dengue outbreak risk in Peru, 2000–2018: a time-series analysis," *PLoS Negl Trop Dis,* vol. 16, no. 6, p. e0010479, 2022.

[7] G. Kuno, "Review of the factors modulating dengue transmission," *Epidemiol. Rev.,* vol. 17, no. 2, p. 321–335, 1995.

[8] Y. L. Hii, N. Rocklöv, M. Ng and A. Ebi, "Forecast of dengue incidence using temperature and rainfall," *PLoS Negl Trop Dis,* vol. 6, no. 11, p. e1908, 2012.

[9] S. T. Stoddard, A. C. Morrison, G. M. Vazquez-Prokopec and e. al., "House-to-house human movement drives dengue virus transmission," *Proc. Natl. Acad. Sci. USA,* vol. 110, no. 3, p. 994–999, 2013.

PHỤ LỤC MINH CHỨNG

```
d:\dengue_gnn_project_do_an\utils\buoc1taoedge.py:60: UserWarning: Geometry is in a geographic CRS
. Results from 'centroid' are likely incorrect. Use 'GeoSeries.to_crs()' to re-project geometries
to a projected CRS before this operation.

  centroids = gdf.geometry.centroid
    Done. Nodes: 5564 | Edges: 16382
- node2idx.json @ data/processed\node2idx.json
- edge_list.csv @ data/interim\edge_list.csv
- edge_index.pt @ data/processed\edge_index.pt
PS D:\dengue_gnn_project_do_an>
```

Hình 3.1 Thực Thi buoc1taoedge.py

```
PS D:\dengue_gnn_project_do_an> & C:\Users\HAI\AppData\Local\Programs\Python\Python310\p
ython.exe d:/dengue_gnn_project_do_an/utils/buoc2taofeature_label.py
 Tạo FEATURE & LABEL theo TUẦN (có diện tích, không dùng date)
 Số node: 5564, edge_index: (2, 16382)
 Đọc environ_vars...
 Đọc IBGE_POPTCU...
 Đọc dengue...
 Đọc climate...
 Xuất CSV đối chứng theo năm & full
 Lưu 760 snapshot .pt @ data/processed\weekly_pt
 Feature columns (14): ['temp_med', 'precip_tot', 'rainy_days', 'rel_humid_med', 'POPULA
CAO', 'altitude', 'area_km2', 'population_density', 'incidence_per_1k', 'humid_heat_inde
x', 'precip_std_roll3', 'dry_spell_len', 'neighbor_cases_prev1', 'incidence_lag1']
PS D:\dengue_gnn_project_do_an>
```

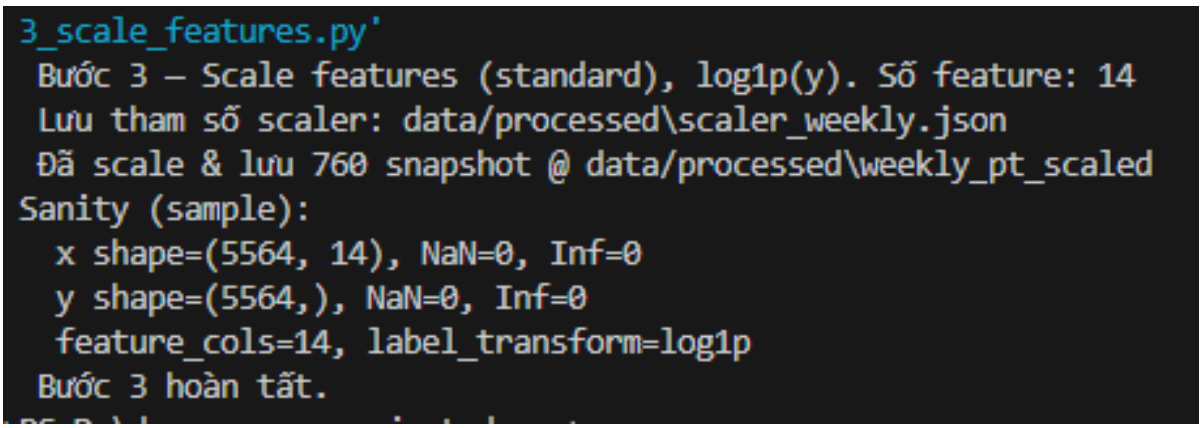
Hình 3.2 Thực Thi buoc2a_taofeature_label.py

```
  node2idx loaded: N=5564
 edge_index shape: (2, 16382)
  edge_index tensor OK
 Found 760 snapshots in data/processed\weekly_pt
  CSV full exists: data/interim\weekly_features_labels.csv with shape (4233146, 21)
  No NaNs in core columns
 Year range: 2010..2024, epiweek range: 201001..202424
 Yearly CSV files: 15
  Per-year CSVs present.
 d:\dengue_gnn_project_do_an\utils\buoc2b_check.py:102: FutureWarning: You are using
 ps://github.com/pytorch/pytorch/blob/main/SECURITY.md#untrusted-models for more deta
 de unless they are explicitly allowlisted by the user via `torch.serialization.add_s
   d = torch.load(p, map_location="cpu")

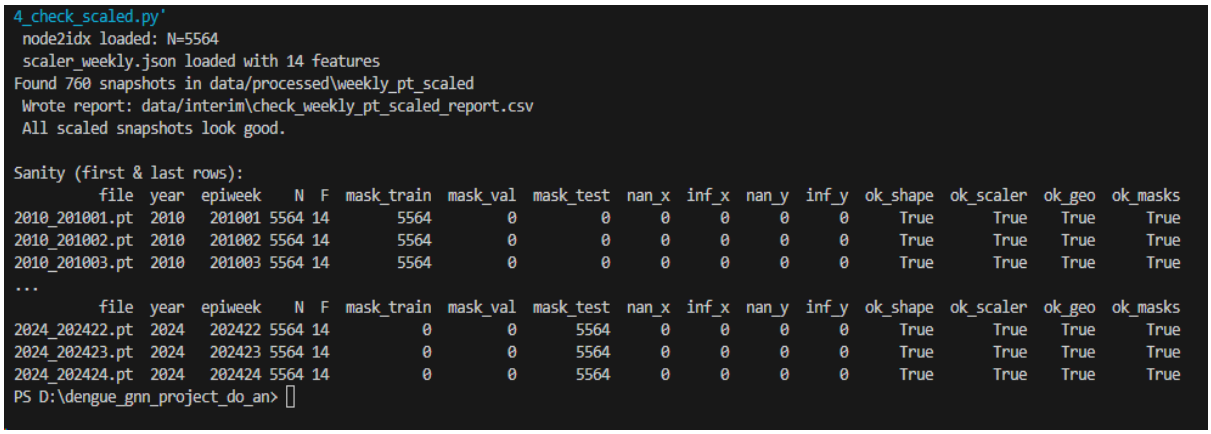
 Inspect: 2010_201001.pt
  x shape OK: (5564, 14) with 14 features
  y shape OK
  geocodes aligned with node2idx
  masks look mutually exclusive
  x has no NaN/Inf
  y has no NaN/Inf
  feature_cols include the expected set (14 cols)

 Sanity stats (from full CSV):
   casos                : min=0.000  p50=0.000  max=48223.000  NaNs=0
   incidence_per_1k     : min=0.000  p50=0.000  max=63.297  NaNs=0
   population_density   : min=0.031  p50=24.983  max=16259.696  NaNs=0
   humid_heat_index     : min=2.430  p50=17.384  max=24.946  NaNs=0
   neighbor_cases_prev1 : min=0.000  p50=2.000  max=57423.000  NaNs=0
```

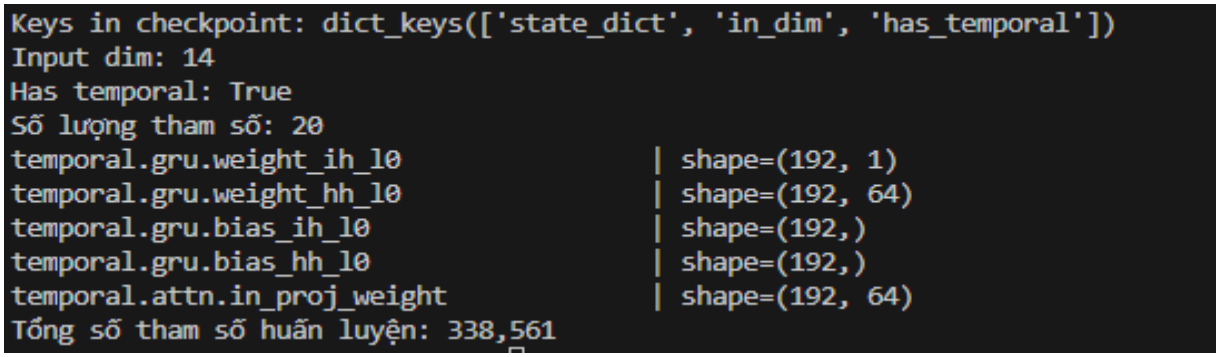
Hình 3.3 Thực Thi buoc2b_check.py



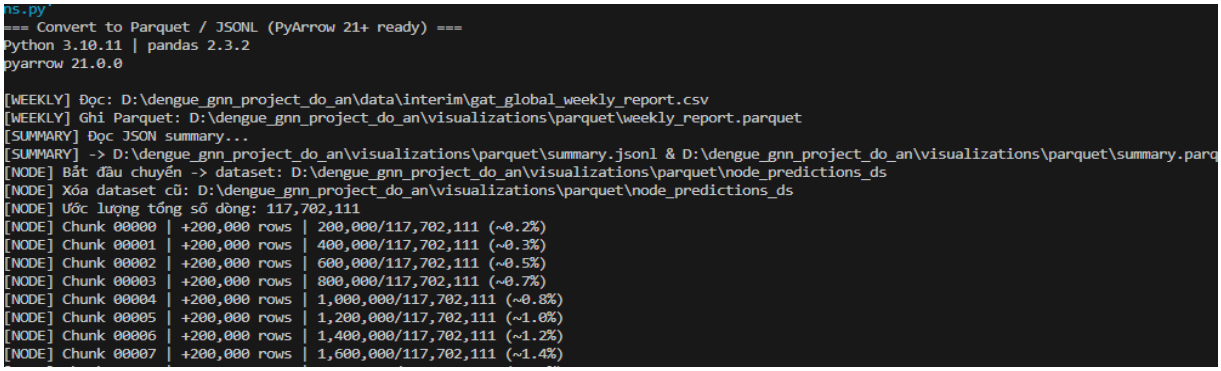
Hình 3.4 Thực thi buoc3_scale_features.py



Hình 3.5 Thực thi buoc4_check_scaled.py



Hình 3.6: Thực thi huấn luyện và kiểm tra checkpoints gat_global_best.pt



Hình 3.7: Thực thi convert_node_predictions.py

```
=== SCHEMA ===
Split: string
geocode: int64
y_true_log: float
y_pred_log: float
y_true: double
y_pred: double
shard: int32
Year: int32
Epiweek: int32
-- schema metadata --
pandas: '{"index_columns": [], "column_indexes": [], "columns": [{"name":' + 980

=== 10 ROWS SAMPLE ===
  Split  geocode  y_true_log  y_pred_log  y_true    y_pred  shard  Year  Epiweek
0   val  1100015    0.000000    0.018665     0.0  0.018840      0  2021   202101
1   val  1100023    1.098612    0.407627     2.0  0.503246      0  2021   202101
2   val  1100031    0.000000   -0.038790     0.0  0.000000      0  2021   202101
3   val  1100049    2.197225    0.544436     8.0  0.723636      0  2021   202101
4   val  1100056    0.693147    0.183700     1.0  0.201656      0  2021   202101
5   val  1100064    0.000000    0.055930     0.0  0.057523      0  2021   202101
6   val  1100072    0.000000    0.090510     0.0  0.094732      0  2021   202101
7   val  1100080    1.609438    0.592755     4.0  0.808965      0  2021   202101
8   val  1100098    0.693147    0.452514     1.0  0.572260      0  2021   202101
9   val  1100106    1.098612    0.528613     2.0  0.696577      0  2021   202101

=== COLUMNS (lower) ===
['split', 'geocode', 'y_true_log', 'y_pred_log', 'y_true', 'y_pred', 'shard', 'year', 'epiweek']

=== Gợi ý cột geocode (khớp tên) ===
['geocode']
PS D:\dengue_gnn_project_do_an>
```

Hình 3.8: Thực thi inspect_node_predictions_schema.py

```
  ... đã ghi 44,934,864 dòng
  ... đã ghi 45,201,936 dòng
  ... đã ghi 45,474,572 dòng
  ... đã ghi 45,744,360 dòng
  ... đã ghi 46,014,280 dòng
  ... đã ghi 46,289,024 dòng
  ... đã ghi 46,559,552 dòng
  ... đã ghi 46,827,820 dòng
  ... đã ghi 47,099,260 dòng
  ... đã ghi 47,371,896 dòng
  ... đã ghi 47,638,968 dòng
  ... đã ghi 47,911,604 dòng
  ... đã ghi 48,183,308 dòng
  ... đã ghi 48,451,312 dòng
  ... đã ghi 48,727,972 dòng
  ... đã ghi 48,996,584 dòng
[PANEL] xong 49,000,000 dòng | 93.3s
[AGG] Tổng hợp theo (year, epiweek) -> panel_node_agg.parquet
[AGG] Ghi: D:\dengue_gnn_project_do_an\visualizations\prepared\panel_node_agg.parquet (104 tuần)
[CHORO] Sinh choropleth JSONL per-week (offline)
[CHORO] Done -> D:\dengue_gnn_project_do_an\visualizations\prepared\choropleth
[EDGE] Đọc CSV: D:\dengue_gnn_project_do_an\data\interim\edge_list.csv
[EDGE] Ghi: D:\dengue_gnn_project_do_an\visualizations\prepared\edges.parquet (E=16,382)
[GEO] Copied -> D:\dengue_gnn_project_do_an\visualizations\geo\geojs-100-mun.json
d:\dengue_gnn_project_do_an\tools\prepare_visual_data.py:371: UserWarning: Geometry is in a geographic CRS. Results from

  cent = gdf.geometry.centroid
[CENTROID] Ghi: D:\dengue_gnn_project_do_an\visualizations\geo\muni_centroids.parquet (5,564 muni)
[ENRICH] Ghi meta tĩnh: D:\dengue_gnn_project_do_an\visualizations\prepared\geocode_meta.parquet (5,564 geocode)
```

Hình 3.9: Thực thi prepare_visual_data.py

```
PS D:\dengue_gnn_project_do_an>  d:; cd 'd:\dengue_gnn_project_do_an'; & 'c:\Users\HAI\AppData\Loca
l\Programs\Python\Python310\python.exe' 'c:\Users\HAI\.vscode\extensions\ms-python.debugpy-2025.10.
0-win32-x64\bundled\libs\debugpy\launcher' '57788' '--' 'd:\dengue_gnn_project_do_an\tools\rebuild_
centroids.py'
=== Rebuild GEO/CENTROID (EPSG:5880 -> EPSG:4326) ===
[GEO] Đọc: D:\dengue_gnn_project_do_an\data\raw\geojs-100-mun.json
[GEO] Khóa: id | Tên: name
[GEO] Tính centroid trong EPSG:5880 ...
[CENTROID] Ghi: D:\dengue_gnn_project_do_an\visualizations\geo\muni_centroids.parquet (5,564 muni)
[GEO] GeoJSON đã có sẵn -> D:\dengue_gnn_project_do_an\visualizations\geo\geojs-100-mun.json
 DONE: muni_centroids.parquet & geojson đã sẵn sàng trong visualizations/geo/
PS D:\dengue_gnn_project_do_an>
```

Hình 3.10: Thực thi rebuild_centroids.py

```
PS D:\dengue_gnn_project_do_an>  d:; cd 'd:\dengue_gnn_project_do_an'; & 'c:\Users\HAI\AppData\Loca
l\Programs\Python\Python310\python.exe' 'c:\Users\HAI\.vscode\extensions\ms-python.debugpy-2025.10.
0-win32-x64\bundled\libs\debugpy\launcher' '57806' '--' 'd:\dengue_gnn_project_do_an\tools\validate
_and_fix_edges.py'
=== Validate & Fix Edges ===
[INFO] Có 5_564 geocode hợp lệ từ centroid
[READ] edge_list.csv: 16_382 dòng, min/max = a[0..5557], b[5..5563]
[DETECT] Diễn giải cạnh dạng: INDEX
[OK] Sau clean còn 16_382 cạnh
[STATS] degree min/median/mean/max = 1/6/5.89/23 (trên 5_564 nút có bậc > 0)
[WRITE] → D:\dengue_gnn_project_do_an\visualizations\prepared\edges.parquet (src,dst=int64)

Tiếp theo hãy chạy:
  python tools/export_dashboard.py --max-edges 12000
PS D:\dengue_gnn_project_do_an>
```

Hình 3.11 Thực thi validate_and_fix_edges.py

```
PS D:\dengue_gnn_project_do_an>  d:; cd 'd:\dengue_gnn_project_do_an'; & 'c:\Users\HAI\AppData\Loca
l\Programs\Python\Python310\python.exe' 'c:\Users\HAI\.vscode\extensions\ms-python.debugpy-2025.10.
0-win32-x64\bundled\libs\debugpy\launcher' '57828' '--' 'd:\dengue_gnn_project_do_an\tools\export_d
ashboard.py'
=== Export advanced visuals (offline, streaming + RAF + Nweeks/Sseconds) ===
[WEEKS] 104 (từ 2021-W101 → 2022-W252)
[EDGE] 12,000 edges
d:\dengue_gnn_project_do_an\tools\export_dashboard.py:388: DeprecationWarning: *choroplethmapbox* i
s deprecated! Use *choroplethmap* instead. Learn more at: https://plotly.com/python/mapbox-to-mapli
bre/
  return go.Choroplethmapbox(
d:\dengue_gnn_project_do_an\tools\export_dashboard.py:413: DeprecationWarning: *choroplethmapbox* i
s deprecated! Use *choroplethmap* instead. Learn more at: https://plotly.com/python/mapbox-to-mapli
bre/
  return go.Choroplethmapbox(
d:\dengue_gnn_project_do_an\tools\export_dashboard.py:452: DeprecationWarning: *densitymapbox* is d
eprecated! Use *densitymap* instead. Learn more at: https://plotly.com/python/mapbox-to-maplibre/
  return go.Densitymapbox(
d:\dengue_gnn_project_do_an\tools\export_dashboard.py:469: DeprecationWarning: *scattermapbox* is d
eprecated! Use *scattermap* instead. Learn more at: https://plotly.com/python/mapbox-to-maplibre/
  return go.Scattermapbox(
d:\dengue_gnn_project_do_an\tools\export_dashboard.py:500: DeprecationWarning: *scattermapbox* is d
eprecated! Use *scattermap* instead. Learn more at: https://plotly.com/python/mapbox-to-maplibre/
  return go.Scattermapbox(
 DONE: visualizations\dashboard_chinhthuc.html
```

Hình 3.12 Thực thi export_dashboard.py